

ÖZET

Bu çalışmada, CNN (Convolutional Neural Network) modellerinin hibritlenmesini araştırır ve bu yaklaşımın görüntü sınıflandırma performansını değerlendirir. CNN modelleri temel prensipleri ve çalışma mekanizmaları açıklanarak, hibritlenme için farklı yöntemler ve stratejiler tartışılır.

Çalışma, CNN modellerinin hibritlenmesi için yeni bir yöntem sunar ve bu yöntem deneysel çalışmalarla değerlendirilir. Sonuçlar, CNN modellerinin hibritlenmesinin tek başına kullanıldıklarında elde edilen sonuçlardan daha iyi performans gösterdiğini gösterir. Geliştirilen hibrit model, daha yüksek sınıflandırma doğruluğu ve daha düşük hata oranları sağlar.

Bu çalışmada, CNN modellerinin hibritlenmesi alanında yapılan araştırmalara katkıda bulunur ve derin öğrenme topluluğuna yeni bir yöntem sunar. Hibritlenmenin, derin öğrenme modellerinin performansını artırma potansiyeline işaret eder.

Anahtar Kelimeler: Derin Öğrenme, CNN, Sınıflandırma, Hibrit Model

SUMMARY

In this study, it investigates the hybridization of CNN (Convolutional Neural Network) models and evaluate the image classification performance of this approach. The basic principles and working mechanisms of CNN models are explained, and different methods and strategies for hybridization are discussed.

The study presents a new method for hybridizing CNN models and this method is evaluated by experimental studies. The results show that hybridization of CNN models outperforms results when used alone. The developed hybrid model provides higher classification accuracy and lower error rates.

This study contributes to research in the field of hybridizing CNN models and presents a new method to the deep learning community. It points to the potential of hybridization to improve the performance of deep learning models.

Keywords: Deep Learning, CNN, Classification, Hybrid Model

İÇİNDEKİLER

ÖZET	4
SUMMARY	5
ÖNSÖZ	6
ŞEKİLLER DİZİNİ	10
TABLO DİZİNİ	11
KISALTMALAR	12
1. GİRİŞ	13
1. LİTERATÜR TARAMASI	14
2. METOD VE METARYAL	18
2.1. VERİ SETİ	18
2.2. SINIFLANDIRMA (CLASSİFİCATION)	21
2.3. MAKİNE ÖĞRENMESİ	21
2.3.1. SVM	22
2.3.2. KNN	24
2.4. DERİN ÖĞRENME	25
2.4.1. DERİN ÖĞRENME KÜTÜPHANELERİ	26
2.4.2. CNN	27
2.4.2.1. LE NET	31
2.4.2.2. ALEX NET	32
2.4.2.3. VGG NET	33
2.4.2.4. RES NET	34
2.4.3. LSTM	36
3. DENEYSEL SONUÇLAR	38
3.1. MODEL VE YÖNTEMLER	38
3.1.1. CNN-LSTM	40
3.1.2. CNN-KNN	40

3.1.3. CNN-SVM.....	40
4. SONUÇ.....	41
4.1. M-NSİT VERİ SETİ İÇİN CNN-LSTM K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI.....	42
4.1.1. DOĞRULUK DEĞERLERİ.....	42
4.1.2. CONFUSİON MATRİX.....	43
4.1.3. SINIFLANDIRMA RAPORU.....	44
4.1.4. ROC EĞRİSİ VE AUC SKORU	45
4.2. MALARİA VERİ SETİ İÇİN CNN-LSTM K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI	46
4.2.1. DOĞRULUK DEĞERLERİ.....	47
4.2.2. CONFUSİON MATRİX.....	48
4.2.3. SINIFLANDIRMA RAPORU.....	49
4.2.4. ROC EĞRİSİ VE AUC SKORU	50
4.3. M-NSİT VERİ SETİ İÇİN CNN-KNN K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI	51
4.3.1. DOĞRULUK DEĞERLERİ.....	51
4.3.2. CONFUSİON MATRİX.....	53
4.3.3. SINIFLANDIRMA RAPORU.....	54
4.3.4. ROC EĞRİSİ AUC SKORU	55
4.4. MALARİA VERİ SETİ İÇİN CNN-KNN K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI	56
4.4.1. DOĞRULUK DEĞERLERİ.....	57
4.4.2. CONFUSİON MATRİX.....	58
4.4.3. SINIFLANDIRMA RAPORU.....	59
4.4.4. ROC EĞRİSİ AUC SKORU	60
4.5. M-NİST VERİ SETİ İÇİN CNN-SVMN K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI	61

4.5.1.	DOĞRULUK DEĞERLERİ.....	61
4.5.2.	CONFUSION MATRIX.....	63
4.5.3.	SINIFLANDIRMA RAPORU.....	64
4.5.4.	ROC EĞRİSİ VE AUC SKORU	65
4.6.	MALARİA VERİ SETİ İÇİN CNN-SVMN K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI	66
4.6.1.	DOĞRULUK DEĞERLERİ.....	66
4.6.2.	CONFUSION MATRIX.....	68
4.6.3.	SINIFLANDIRMA RAPORU.....	69
4.6.4.	ROC EĞRİSİ VE AUC SKORU	69
5.	KAYNAKÇA.....	71

ŞEKİLLER DİZİNİ

Şekil 1 Hybrid Model	18
Şekil 2 Mnist Veri Setinden Örnek Görseller	19
Şekil 3 Mnist Veri Setindeki İlk 10 Görüntü	19
Şekil 4 Malaria Veri Setindeki Parasitized Sınıfından Örnek Görseller	20
Şekil 5 Malaria Veri Setindeki Uninfected Sınıfından Örnek Görseller	20
Şekil 6 SVM.....	22
Şekil 7 KNN Mimari Yapısı	24
Şekil 8 Kullanılan Görsel.....	27
Şekil 9 Uygulanan Filtre	28
Şekil 10 Sonuç Matrisi	28
Şekil 11 Non-Linear Katmanının Uygulanışı	29
Şekil 12 Maxpooling İşlemi.....	29
Şekil 13 Flatting İşlemi.....	30
Şekil 14 Fully-Connected İşlemi.....	30
Şekil 15 Le Net Mimari Yapısı	31
Şekil 16 Alex Net'in Temel Mimarisi.....	33
Şekil 17 VGG-16 Mimari Yapısı	34
Şekil 18 VGG-19 Mimari Yapısı	34
Şekil 19 Artık Bloğu.....	35
Şekil 20 ResNet Mimari Yapısı	36
Şekil 21 LSTM Yapısı.....	37
Şekil 22 Proje Akış Şeması.....	39
Şekil 23 CNN-LSTM M-NİST DOĞRULUK GRAFİĞİ	42
Şekil 24 CNN-LSTM M-NİST KAYIPGRAFİĞİ	43
Şekil 25 CNN-LSTM MNİST Veri Seti Kullanarak Oluşturulan Confusion Matrix	44
Şekil 26 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-LSTM Sınıflandırma Raporu	45
Şekil 27 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-LSTM Sınıf Bazlı ROC Eğrileri	46
Şekil 28 CNN-LSTM MALARİA DOĞRULUK GRAFİĞİ.....	47
Şekil 29 CNN-LSTM MALARİA KAYIPGRAFİĞİ	48
Şekil 30 CNN-LSTM Malaria Veri Seti Kullanarak Oluşturulan Confusion Matrix	49
Şekil 31 Malaria Veri Seti Kullanılarak Oluşturulan CNN-LSTM Sınıflandırma Raporu	50
Şekil 32 Malaria Veri Seti Kullanılarak Oluşturulan CNN-LSTM Sınıf Bazlı ROC Eğrileri	51

Şekil 33 CNN-KNN M-NİST DOĞRULUK GRAFİĞİ	52
Şekil 34 CNN-KNN M-NİST KAYIP GRAFİĞİ	53
Şekil 35 CNN-KNN M-NİST Veri Seti Kullanarak Oluşturulan Confusion Matrix	54
Şekil 36 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-KNN Sınıflandırma Raporu	55
Şekil 37 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-KNN Sınıf Bazlı ROC Eğrileri ..	56
Şekil 38 CNN-KNN Malaria DOĞRULUK GRAFİĞİ	57
Şekil 39 CNN-KNN Malaria KAYIP GRAFİĞİ	58
Şekil 40 CNN-KNN Malaria Veri Seti Kullanarak Oluşturulan Confusion Matrix	59
Şekil 41 Malaria Veri Seti Kullanılarak Oluşturulan CNN-KNN Sınıflandırma Raporu	60
Şekil 42 Malaria Veri Seti Kullanılarak Oluşturulan CNN-KNN Sınıf Bazlı ROC Eğrileri ..	61
Şekil 43 CNN-SVM M-NİST DOĞRULUK GRAFİĞİ	62
Şekil 44 CNN-SVM M-NİST KAYIP GRAFİĞİ	62
Şekil 45 CNN-SVM M-NİST Veri Seti Kullanarak Oluşturulan Confusion Matrix	63
Şekil 46 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-SVM Sınıflandırma Raporu	64
Şekil 47 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-SVM Sınıf Bazlı ROC Eğrileri ..	65
Şekil 48 CNN-SVM Malaria DOĞRULUK GRAFİĞİ	66
Şekil 49 CNN-SVM Malaria KAYIP GRAFİĞİ	67
Şekil 50 CNN-SVM Malaria Veri Seti Kullanarak Oluşturulan Confusion Matrix	68
Şekil 51 Malaria Veri Seti Kullanılarak Oluşturulan CNN-SVM Sınıflandırma Raporu	69
Şekil 52 Malaria Veri Seti Kullanılarak Oluşturulan CNN-SVM Sınıf Bazlı ROC Eğrileri ...	70

TABLO DİZİNİ

Tablo 1 Derin Öğrenme Kütüphaneleri	26
---	----

KISALTMALAR

CNN: Convolutional Neural Network

RNN: Recurrent Neural Network

Mask R-CNN: Mask Region Convolutional Neural Network

MS: Multipl Skleroz

MR: Manyetik Rezonans

RESNET: Residual Network

VGGNET: Visual Geometry Group Network

NASNET: Neural Architecture Search Network

ALEXNET: ALEX NETWORK

LENET: LE NETWORK

MOBILENET: MOBILE NETWORK

ZFNET: Zeiler & Fergus Network

DENSENET: Densely Connected Convolutional Networks

MLP: Multi-layer Perceptron

NB: Naïve Bayes

SDN: Software-Defined Networking

DNN: Deep Neural Network

RELU: Rectified Linear Unit

SVM: Support Vector Machine

KNN: K-Nearest Neighbor

LSTM: Long Short-Term Memory

MNIST: Modified National Institute of Standards and Technology

AUC: Area Under The Curve

FPR: False Positive Rate

FDR: False Discovery Rate

FNR: False Negative Rate

ABD: Amerika Birleşik Devletleri

1. GİRİŞ

Bu projenin amacı derin öğrenme teknikleri kullanılarak yeni bir derin öğrenme modeli ortaya koyarak bir sınıflandırma yapmaktır. Sınıflandırma kavramı veri seti üzerinde tanımlanan sınıflar arasında veriyi dağıtmaktadır. Bu çalışmada veri seti en az iki sınıftan oluşturulması hedeflenmektedir. Sınıflandırma algoritmaları verilen eğitim kümesinden nesneyi öğrenirler ve daha sonra test verileri geldiğinde sınıflandırmaya çalışır [1].

Verinin temsilinden öğrenmeye dayalı olduğu derin öğrenme algoritması bir resim için temsil ifade ediliyorsa bu resmin yoğunluk değerleri, resmin boyutu şekli, arka planı vb. özellikler olarak ifade edilebilir. Bu özelliklerin bazıları veriyi daha iyi temsil ettiği için derin öğrenme algoritması makine öğrenmesinin aksine veriyi elle değil algoritmalar yöntemi ile bu işlemi yapar. Bu işleme de özellik çıkarımı adı verir. Bu algoritmalarından biri de CNN algoritmasıdır [2].

Bu çalışmada Convolutional Neural Network (CNN) modellerinin hibritlenmesi üzerine bir inceleme yapılmıştır. Geleneksel olarak, CNN'ler görüntü işleme ve desen tanıma gibi görevlerde etkili sonuçlar vermiştir. Ancak, bazı uygulamalarda, yetersiz performans veya veri eksikliği gibi zorluklarla karşılaşabilirler. Bu nedenle, farklı öğrenme yöntemlerini birleştirerek daha güçlü ve daha esnek modeller oluşturmak için hibritleme stratejileri geliştirilmiştir. CNN modellerinin hibritlenmesi için çeşitli yaklaşımlar incelenmiştir. İlk olarak, transfer öğrenme yöntemleri kullanılarak, önceden eğitilmiş bir CNN modelinin ağırlıkları başka bir görevde yeniden kullanılarak yeni bir model oluşturulmuştur. Bu yaklaşım, sınırlı veriyle çalışma durumlarında etkili sonuçlar elde etmek için kullanışlı olabilir.

Ayrıca, CNN'lerin diğer makine öğrenmesi algoritmalarıyla birleştirildiği hibrit modeller de araştırılmıştır. Örneğin, CNN ve RNN (Recurrent Neural Network) modelleri birleştirilerek, zaman serisi verilerinin işlenmesinde daha iyi performans elde edilmiştir. Ayrıca, CNN ve genetik algoritma gibi evrimsel hesaplama tekniklerinin birleştirildiği hibrit modeller, parametre optimizasyonu gibi zorlu görevlerde etkili olmuştur.

Sonuç olarak, CNN modellerinin hibritlenmesi, daha karmaşık ve genel amaçlı öğrenme modellerinin oluşturulmasında önemli bir rol oynamaktadır. Bu çalışmada incelenen yaklaşımlar, performansını artırmak, veri eksikliğini gidermek veya belirli görevlere özgü ihtiyaçları karşılamak için kullanılabilir. Gelecekte, daha fazla hibritleme stratejisinin geliştirilmesi ve farklı uygulama alanlarında test edilmesi önemli bir araştırma alanı olabilir.

1. LİTERATÜR TARAMASI

Bu projede Derin öğrenme tekniklerinden yararlan ve çiçek türleri tanıyabilen bir algoritma geliştirilmiştir. Çiçek görüntüsünü tahmin eden bir yazılım geliştirilmiştir. Veri seti olarak Oxford 102 veri seti kullanılmıştır. Görüntü işleme alanında Resnet152 modeli kullanılmıştır. Çünkü görüntü işleme konusunda oldukça başarılı olan ResNet152 modeli test görüntüleri için sınıflandırma başarı %99'dur. Aynı veri setini kullanıp başka modeller üzerinde test edilmiştir en yüksek başarıyı ResNet152 modeli elde etmiştir [3].

Bu çalışmada Denge bozukluğu olan bir sinir hastalığı olan Multipl Skleroz hastalığı üzerinde bir çalışma yapılmıştır. Plantar basınç dağılım sinyalleri içeren görüntüleri kullanarak MS hastalarında ataksiyi tespit etmeyi amaçlar. Hastalığı olan ve olmayan sağlıklı olan bireylerin plantar basınç sinyali içeren 418 görüntü önceden eğitilmiş Hibrit CNN Ağlar yardımı ile sınıflandırılmıştır. Bu Cnn Modelleri; VGG16, VGG19, ResNet, MobilNet, NasNet'tir. Sonuç olarak bu çalışma da farklı Cnn modellerinin hibritlenebileceği sonucuna varılmıştır [4].

Bu projede Covid-19 hastalığı için hibrit modellemesi kullanılmıştır. Bu hibrit model için Derin öğrenme ve Makine öğrenmesi sınıflandırma algoritmaları hibritlenmiştir. Kullanılan bu modeller; CNN-SVM, CNN-KNN, CNN-MLP, CNN-NB'dir. CNN özellik çıkarmak için kullanılırken diğerleri bir sınıflandırma için kullanılmıştır. Kısacası bu kullanılan hibrit yöntemler AUC skoru, hassasiyet, doğruluk, kesinlik, F1 skoru, özgüllük, FPR, FDR ve FNR gibi değerler karşılaştırılmaktadır ve en iyi sonuçları CNN-SVM vermektedir. Yani hibrit model Covid-19 tespitinde verimli olduğu gözlemlenmiştir [5].

Bu çalışmanın amacı Mask R-CNN arayüzünde bulunan orijinal backbone yapısını hibritleyerek kedi ve köpeklerde kırık tespiti yapmayı hedeflemiştir. Bu sayede daha hızlı ve yüksek performans ile kırık tespiti yapılacaktır. Yapılmayı hedeflenen hibrit çalışmada yüksek doğruluk oranı veteriner vb. doktorların kırık teşhisine yardımcı olması hedeflenmiştir. Veri setinde toplamda 512 adet görüntü bulunmaktadır. Kedi ve köpeğe ait tibia kırık görüntülerinin olduğu bu veri setinde kırık olan görüntüler için F1 skor değeri kedi için %77,7 köpek %87,8 ve toplam veri seti için %87,8dir [6].

Yazılım Tanımlı Ağ yani SDN, güç iletişim ağının performansını artırabilir ve Akıllı Şebekenin merkezi yönetimi için kontrol talebini daha iyi karşılayabilir. Ne yazık ki, SDN denetleyicisi birçok potansiyel ağ saldırısına karşı savunmasızdır. Anormal akışın doğru tespiti, Akıllı Şebeke'nin güvenliği ve güvenilirliği için özellikle önemlidir. Büyük ve yüksek boyutlu ağ akışı için düşük doğrulukla, basit ve yüzeysel özellik öğrenimlidirler. Yukarıda ki sorunları ele almak

iin, bir Hibrit Konvolüsyonel Sinir Ağı (HYBRID-CNN) yöntemi önerilmiştir. Spesifik olarak, HYBRID-CNN, küresel özellikleri tek boyutlu (1D) verilerle etkili bir şekilde ezberlemek için bir Derin Sinir Ağı (DNN) kullanır ve yerel özellikleri iki boyutlu (2D) verilerle genelleştirmek için bir CNN kullanır. Bu hibrit örneğinde modeli üç paraya ayırmıştır; özellik çıkarımı, özellik birleştirme ve sınıflandırma bölümleridir. Özellik çıkarımı, akış özelliğini daha kapsamlı çıkarmayı hedeflerken Dikkat Mekanizması özelliğı birleştirmeyi ve doğru şekilde sınıflandırma yapılması hedeflenmiştir. Son olarak, önerilen yöntem, UNSW_NB15 ve KDDCup 99 veri kümeleri üzerinde yapılan deneylerle değerlendirilmiştir. Deneyisel sonuçlar, HYBRID-CNN'nin doğruluk ve Yanlış Pozitif Oranı (FPR) açısından mevcut yöntemlerden önemli ölçüde daha iyi performans gösterdiğini göstermektedir [7].

Bu projede, sahne sınıflandırması, insanın biyolojik sistemlerini taklit ederek görüntülerden bilgi toplayan ve onları bilgisayar sistemi kullanarak yorumlayan görüntü anlamının önemli bir araştırma dalıdır. AlexNet modeli, büyük evrişim çekirdeğı ve özellik haritalarının çözünürlüğünde aşırı hızlı düşüşe ve uzamsal bilginin aşırı sıkıştırılmasına yol açan ilk evrişimsel katmandaki adım nedeniyle görüntü sınıflandırmasında sınırlıdır. Bu makale, evrişimli sinir ağlarının (CNN'ler) tasarım ilkesine göre geliştirilmiş bir AlexNet modeli önerilmiştir. Büyük evrişim çekirdeğı, azaltılmış adımlı iki küçük evrişim çekirdeğı tarafından basamaklandırılmış bir yapıya ayrıştırılır. Alt düzey özelliklerin veya uzamsal bilgilerin entegrasyon sürecini geliştirmek için ilkinden sonra başka bir evrişimli katman eklenir. Asimetrik evrişim çekirdeğı, son üç evrişim katmanına uygulanır. İki veri seti üzerinde yapılan deneyler, geliştirilmiş AlexNet modelinin sınıflandırma doğruluğunun, 23 sahne sınıflandırma kategorisi için AlexNet modeli ve ZFNet modelinden daha yüksek olduğunu göstermektedir [8].

Bu projede, Bağışıklık sistemi oluşturan en önemli hücrelerden biri olan beyaz kan hücreleri üzerinde bir çalışma gerçekleştirilmiştir. Beyaz kan hücreleri vücudumuzu koruyan hücrelerdir. Hastalıkları teşhis için beyaz kan hücresinden çıkan değerler de büyük öneme sahiptir. Kan tahlili yaptırmak zaman kaybına yol açmaktadır. Zaman kaybının yanı sıra tahlil sonuçlarında hatalarda meydana gelebilir. Oluşan hataları önlemek, zaman kaybını azaltmak, doktor vb. Kişilerin iş yükünü azaltmak için bir bir bir çalışma oluşturulmuştur. Bu projede, 12442 beyaz kan hücresinde oluşan veri setinde 4 tür beyaz kan hücresinin sınıflandırılması amaçlanmıştır. Veri setindeki görüntüler önce CNN (Convolutional Neural Networks) ile sınıflandırılmış, ardından sınıflandırma işlemi için Con-SVM kullanılmıştır. CNN modeliyle doğruluk değeri %83,9 elde edilirken, Hibrit modelde %85 doğruluk oranı elde edilmiştir [9].

Mısır yaprağındaki hastalıkların tespiti için kullanılan VGG-19, DenseNet-201, NasNet-Large CNN modelleri ile özellik çıkarımı yapılmıştır. Mısır yaprağındaki hastalıkları sınıflandırmak için SVMs algoritması kullanılmıştır. Bu algoritmanın verimliliğini artırmak için, GridSearchCV kullanılarak mısırın dış hastalıklarını incelemek için Çekirdek işlevi ve Kutu kısıtlaması hiperparametreleri optimize edilmiştir. Kaggle veri setinde elde edilen işlemlerin sonuçları test edilmiştir. Elde edilen tedavi sonuçlarında CNN ile sadece özellik çıkarımının yapıldığı gözlemi LibSVM ile yapılmamış olup doğruluk oranları %94,5, %94,4, %94,3 ve %96,2 ve 4 için ortalama %94,3 olarak elde edilmiştir. Böylece optimizasyon yapılmadan elde edilen hücrelere göre genişletilerek elde edilen pencere hücreleri birinci sırada %2,2, ikincide %2,3, üçüncüde %2,4. dördüncüde %1,6 ve kapsamlı için %2'dir [10].

Beyin tümörü, beyin veya kafatası içindeki hücrelerin düzensiz gelişiminin neden olduğu hayatı tehdit eden nörolojik bir durumdur. Bu duruma sahip kişilerin ölüm oranı giderek artmaktadır. Kötü huylu tümörlerin erken teşhisi, hastalara tedavi sağlamak için kritik öneme sahiptir ve erken teşhis, hastanın hayatta kalma şansını artırır. Yeterince tedavi edilmezlerse hastanın hayatta kalma oranı genellikle çok daha azdır. Bir beyin tümörü erken bir aşamada tespit edilemezse, kesinlikle ölüme yol açabilir. Bu nedenle, beyin tümörlerinin erken teşhisi, otomatik bir aracın kullanılmasını gerektirir. Kontamine tümör alanlarının manyetik rezonans (MR) görüntülerinden segmentasyonu, teşhisi ve izolasyonu başlıca endişe kaynağıdır. Ancak, radyologların veya klinik uzmanların üstlenmesi gereken meşakkatli ve zaman alıcı bir süreçtir ve performansları tamamen uzmanlıklarına bağlıdır. Bu sınırlamaları ele almak için bilgisayar destekli tekniklerin kullanımı kritik hale gelir. Bu yazıda, herhangi bir insan müdahalesi olmadan beyin tümörü görüntülerini sınıflandırmak için farklı geleneksel ve hibrit makine öğrenimi modelleri oluşturuldu ve ayrıntılı olarak analiz edildi. Bunların yanı sıra 16 farklı transfer öğrenme modeli de analiz edilerek beyin tümörlerini sinir ağlarına dayalı olarak sınıflandırmak için en iyi transfer öğrenme modeli belirlendi. Son olarak, farklı en son teknolojiler kullanılarak, diğer tüm gelişmiş modellerden daha iyi performans gösteren yığılı bir sınıflandırıcı önerilmiştir. Önerilen VGG-SCNet'in (VGG Stacked Classifier Network) kesinlik, hatırlama ve fl puanları sırasıyla %99,2, %99,1 ve %99,2 olarak bulundu [11].

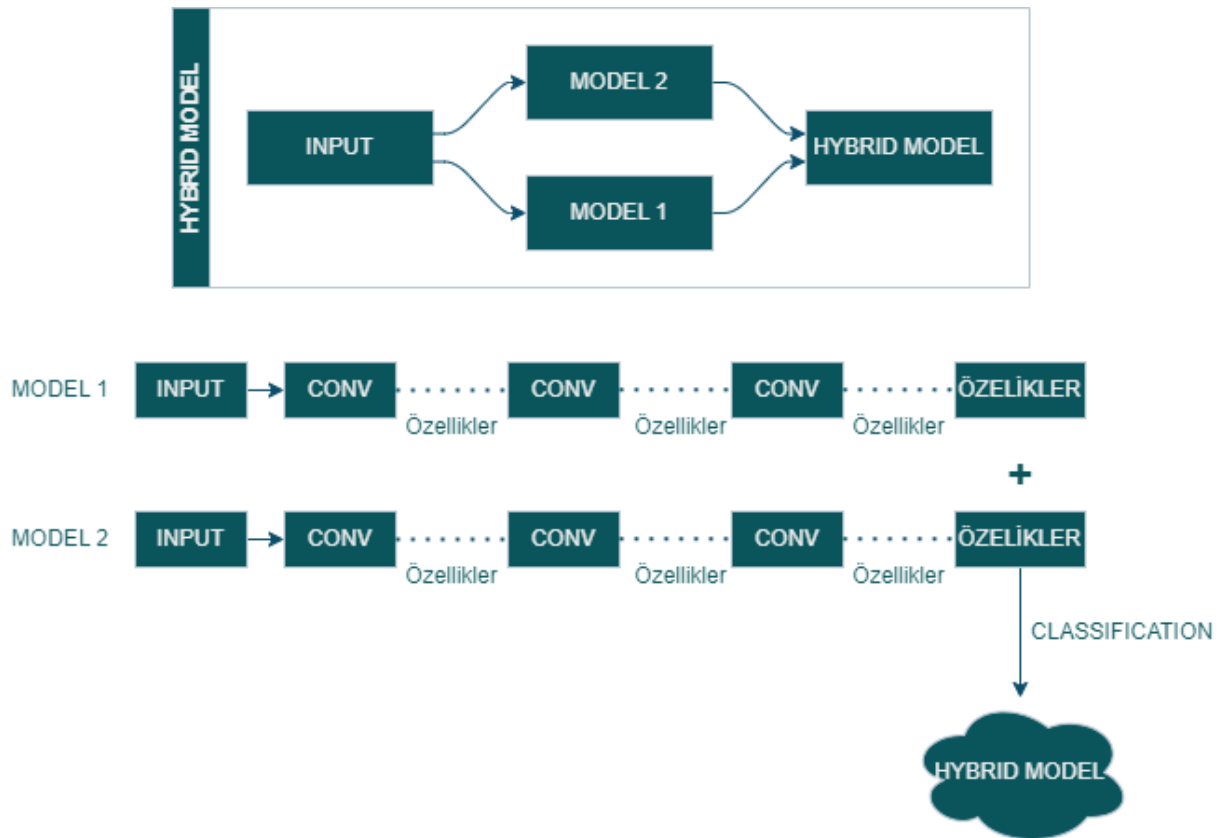
Ülkemizde mermer ve granit rezervine sahiptir. 120 çeşit farklı renk ve desende mermer rezervi 20'ye yakın granit rezervine sahiptir. Mermer ve granit yapısının renk, doku, desen vb. özellikleri nedeniyle ayırt edilmeleri oldukça zordur. Bu durum soruna sebep olmaktadır. Bu sorunu ortadan kaldırmak için mermer ve granitleri sınıflandırmak için yöntem geliştirilmiştir. Projede kullanılan veri seti granit ve mermer satan mağazalar ve taş ocaklarından alınan

görüntülerle oluşturulmuştur. Granit ve mermerlerin renk-desen gibi fotoğrafları ve saklama koşullarından hasar görmüş görüntülerde veri setine dahil edilmiştir. 88 adet mermer ve 14 adet granit görüntüsü toplamda 102 taşa ait 24480 farklı görüntü ile veri seti oluşturulmuştur. Bu veri setine CNN ile eğitilmiş. Ezberlemenin önüne geçmek için K katlı çapraz doğrulama tekniği olan Stratified Shuffle kullanılmıştır. En başarılı model %97,4 başarı göstermiştir. 7 adet model ile test edilmiştir [12].

Bu çalışmada, kontrolsüz bir şekilde büyüyen yazılı sosyal paylaşım verilerinden doğal dil işleme yoluyla içerikleri kategorize etmeyi amaçlamaktadır. Artan bir kullanıcı ağına sahip kategorize olmayan sosyal medya kullanıcıları, olumsuz ve olumsuz içeriklerle sosyal medya kullanıcılarını rahatsız edebilir. Belirtilen nedenlerle, bu sorunu çözmek için hibrit model geliştirilmiştir. Önerilen hibrit model CNN-LSTM hibritidir. Hibrit model keras kullanılarak sosyal paylaşım sistemi arklı kategorilerdeki içeriklerinin otomatik olarak yerleştirilmesi amaçlanmaktadır. Bu çalışma literatürdeki diğer çalışmalardan daha iyi sonuçlar elde etmiştir. Gözlemlenen performans sonuçları, kullanılan yöntemlerden farklı olarak çok etiketli metin çözümleme problemlerine uygulanabileceğini göstermektedir [13].

COVID-19 salgını sırasındaki kısıtlamalar ve kapatmalar, küresel tedarik zincirlerini büyük ölçüde etkiledi. Lojistik sektörü de bu süreçten en çok etkilenen sektörlerin başında geliyor. Bu nedenle, etkin kaynak planlaması için lojistik talebin doğru ve hızlı tahmini önemlidir. Bu çalışmanın amacı, COVID-19 pandemi döneminde üçüncü taraf bir lojistik firmasındaki talebi doğru bir şekilde tahmin etmektir. Bir lojistik firmasının Haziran 2020 ile Aralık 2020 arasındaki sevkiyat verileri incelenmiş ve tahmin problemi tek değişkenli bir zaman serisi olarak ele alınmıştır. Çalışma kapsamında derin öğrenme tabanlı bir talep tahmin modeli önerilmiştir. Önerilen tahmin modelinde, CNN ve uzun kısa süreli bellek LSTM entegre edilmiştir. CNN ile özellik çıkarımı yapılırken, LSTM uzun vadeli bağımlılıkları yakalar ve önerilen modele hibrit CNN-LSTM adı verilir. Hibrit CNN-LSTM' nin tahmin performansı, klasik tahmin yaklaşımlarının yanı sıra makine öğrenmesi ve derin öğrenme yaklaşımları ile karşılaştırılarak değerlendirilmiştir. Hibrit model en yüksek performansı sağlamıştır [14].

2. METOD VE METARYAL



Şekil 1 Hybrid Model

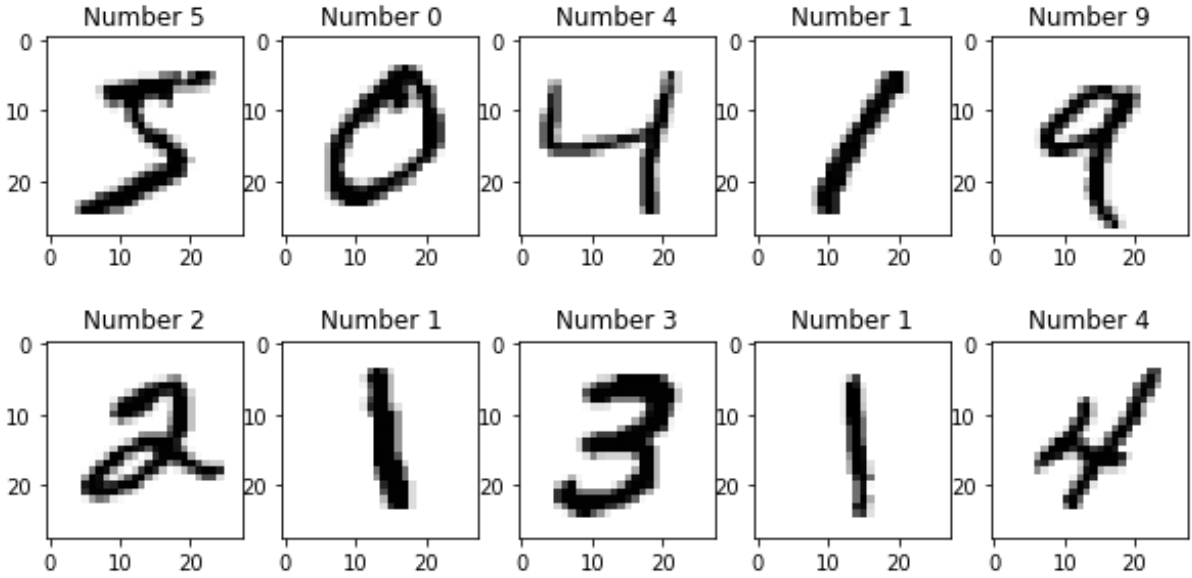
CNN algoritması kullanılarak özellik çıkarımı yapılır çıkarılan özellikler bir makine öğrenmesi yardımı ile sınıflandırılarak ya da derin öğrenme algoritmalarını kullanarak bir hibrit model oluşturulur. Oluşturulan hibrit modellerin performansı değerlendirilir.

2.1. VERİ SETİ

MNIST (Modified National Institute of Standards and Technology) veri seti, el yazısı rakamlarının tanınması için kullanılan bir makine öğrenimi veri setidir. Veri seti, 60.000 eğitim örneği ve 10.000 test örneği içerir. Her örnek, 28x28 piksel boyutunda bir resim olup, her piksel 0 ile 255 arasında bir değere sahiptir ve beyaz arka plan üzerine siyah bir rakam yazılıdır. MNIST veri seti, görüntü işleme, makine öğrenimi ve yapay zeka alanlarında sıklıkla kullanılan bir referans veri setidir. Bu veri seti, birçok öğrenme algoritmasının ve sınıflandırma yönteminin performansını değerlendirmek için kullanılmıştır. Ayrıca, bu veri seti üzerinde öğrenme algoritması geliştirmek için yarışmalar düzenlenmiştir. MNIST veri seti, kolayca indirilebilir ve kullanılabilir durumdadır. Bu veri setini kullanarak, öğrenme algoritmalarınızı ve sınıflandırma yöntemlerinizi test edebilir ve doğruluğunu değerlendirebilirsiniz [15].




Şekil 2 Mnist Veri Setinden Örnek Görseller




Şekil 3 Mnist Veri Setindeki İlk 10 Görüntü

Malaria veri seti, makine öğrenimi ve veri bilimi alanlarında kullanılan bir veri setidir. Bu veri seti, hücre görüntülerinde (hücrelerin mikroskopta görüntülenmesi) plasmodium parazitinin varlığını belirlemek için kullanılır. Plasmodium paraziti, malarya hastalığına neden olan bir parazittir. Malaria veri seti, iki farklı sınıfta (plasmodium içeren hücreler ve içermeyen

hücreler) yaklaşık 27.558 görüntüden oluşur. Bu görüntüler, ortalama 1.500 x 1.500 piksel boyutunda ve hem enfekte hem de sağlıklı hücreler içerir. Bu çalışmada veri集中的 görüntüler yeniden boyutlandırılmıştır ve 64x64x3 boyutlarındadır. Veri seti, ABD Ulusal Sağlık Enstitüleri tarafından sağlanmıştır. Bu veri seti, görüntü işleme ve makine öğrenimi algoritmaları için bir sınıflandırma görevi sağlar. Örneğin, bir sinir ağı kullanarak, hücre görüntülerini sınıflandırmak ve enfekte hücreleri tespit etmek mümkündür. Bu veri seti, malarya hastalığının erken teşhisinde ve tedavisinde kullanılan yapay zeka tabanlı yöntemlerin geliştirilmesinde de kullanılabilir [16].



Şekil 4 Malaria Veri Setindeki Parasitized Sınıfından Örnek Görseller



Şekil 5 Malaria Veri Setindeki Uninfected Sınıfından Örnek Görseller

2.2. SINIFLANDIRMA (CLASSİFİCATION)

Sınıflandırma, verileri belirli kriterlere göre gruplandırma işlemidir. Bir veri kümesindeki öğeleri benzer özelliklere veya karakteristiklere göre sınıflara ayırmayı amaçlar. Sınıflandırma, makine öğrenmesi ve veri madenciliği gibi alanlarda yaygın olarak kullanılan bir tekniktir. Sınıflandırma işlemi, önceden belirlenmiş bir dizi etiket veya sınıf kullanılarak gerçekleştirilir. Bu etiketler, veri noktalarının hangi sınıfa ait olduğunu belirtir. Sınıflandırma algoritması, girdi verilerinin özelliklerini analiz ederek ve öğrenerek, yeni ve bilinmeyen örnekleri doğru sınıflara atamak için bir model oluşturur [17].

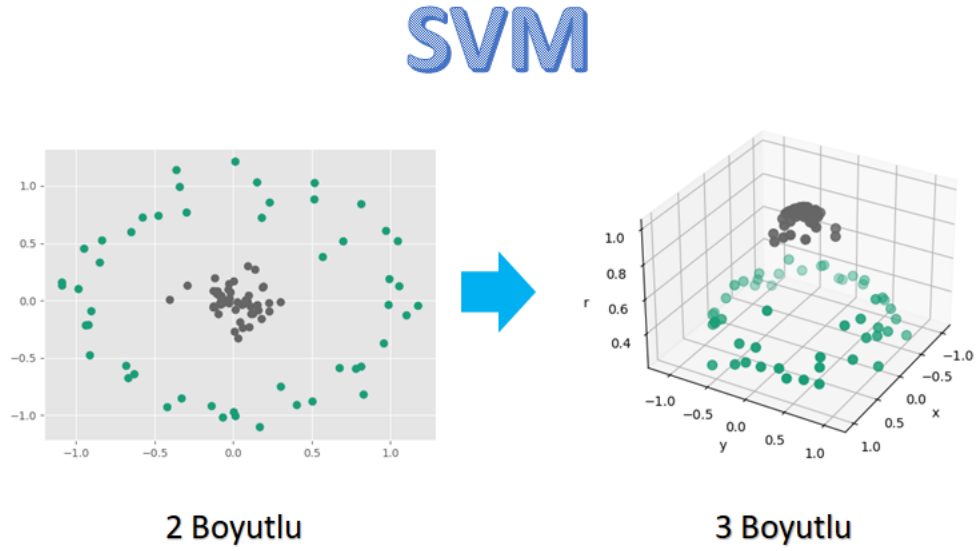
Sınıflandırma problemleri çeşitli alanlarda karşımıza çıkabilir. Örneğin, e-postaların spam veya spam olmayan olarak sınıflandırılması, hastaların bir hastalığa sahip olup olmadığının belirlenmesi, el yazısı tanıma, görüntü veya nesne tanıma gibi birçok uygulama sınıflandırma yöntemlerini gerektirebilir. Sınıflandırma algoritmaları arasında en yaygın kullanılanlar arasında karar ağaçları, destek vektör makineleri (SVM), k-NN (k en yakın komşu), doğal dil işleme için naive Bayes ve derin öğrenme yöntemleri bulunur. Bu algoritmalar, çeşitli özellikler ve veri yapılarına göre farklı avantajlara sahiptir [18].

2.3. MAKİNE ÖĞRENMESİ

Makine öğrenimi, bilgisayar sistemlerinin verilerden öğrenme yoluyla bilgi ve deneyim kazanmasını sağlayan bir yapay zeka dalıdır. Geleneksel programlamadan farklı olarak, makine öğrenimi algoritmaları verileri analiz ederek desenleri, ilişkileri ve kuralları keşfetmeye çalışır ve bu bilgileri gelecekteki tahminlerde, karar verme süreçlerinde veya görevleri yerine getirmede kullanır. Makine öğrenimi algoritmaları, genellikle büyük miktarda veriye dayanarak model oluşturur ve bu modele dayanarak gelecekteki olayları tahmin eder veya belirli bir amaca yönelik kararlar alır. Örnek veriler kullanılarak eğitilen bir model, yeni verilere dayalı olarak sınıflandırma, regresyon, kümeleme, desen tanıma gibi çeşitli görevleri yerine getirebilir. Makine öğrenimi yöntemleri genellikle iki ana kategoriye ayrılır: denetimli öğrenme ve denetimsiz öğrenme. Denetimli öğrenme, verilerin etiketlenmiş örneklerini kullanarak bir modeli eğitmeyi içerir. Örnek olarak, verilerin girdileri ve beklenen çıktıları (etiketleri) belirliyoruz ve model bu ilişkiyi öğrenmeye çalışıyor. Denetimsiz öğrenme ise etiketlenmemiş verileri analiz ederek desenleri keşfetmeye çalışır ve veri kümesini benzerlik, gruplar veya yapılar açısından bölerek anlam çıkarmayı hedefler. Makine öğrenimi, birçok farklı alanda uygulama bulmuştur. Örneğin, görüntü ve ses tanıma, doğal dil işleme, otomatik sürüş, finansal analiz, sağlık hizmetleri ve pazarlama gibi alanlarda makine öğrenimi algoritmaları

kullanılmaktadır. Makine öğrenmesi algoritmaları sınıflandırma yapmak yaygın kullanılan yöntemlerdir. Bu algoritmalar KNN, SVM, Random Forest gibi algoritmalar bunlara birer örnektir[19].

2.3.1. SVM



Şekil 6 SVM

Support Vector Machine (SVM), sınıflandırma ve regresyon problemlerinde kullanılan bir makine öğrenmesi algoritmasıdır. SVM, farklı sınıflara ait verileri bir hiperdüzlem ile ayırmayı amaçlayan bir yaklaşımdır. SVM, lineer ve non-lineer verileri de sınıflandırabilir.

SVM'nin çalışma prensibi, sınıflandırma probleminin iki sınıf halinde düşünülmesine dayanır. Veri noktaları, iki sınıf arasında bir hiperdüzlem ile ayrılır. SVM, bu hiperdüzlemin sınıflandırma işlemindeki konumunu belirlemek için bir optimizasyon problemi formülü kullanır. Bu optimizasyon problemi, veri noktalarının ayrılığına ilişkin bir kısıtlama koşulu altında, hiperdüzlemin en geniş olacak şekilde konumlandırılmasını sağlar [20].

SVM'nin matematiksel formülasyonu, bir dizi denklem ve kısıtlama koşulunu içerir. SVM'nin lineer sınıflandırma problemleri için kullanılan temel matematiksel formülasyonu şu şekildedir:

$$y_i(w \cdot x_i + b) \geq 1$$

Burada, x_i veri noktası, y_i sınıf etiketi (+1 veya -1), w hiperdüzlemdeki normal vektör, b ise hiperdüzlemin kesişim noktasının konumunu belirleyen bir sabittir.

Bu denklem, her veri noktasının en azından bir sınıfta yer alması gerektiği kısıtlamasını ifade eder. SVM, bu kısıtlamayı en küçük birleştirme hatasıyla uyumlu hiperdüzlemi bulmak için kullanır.

SVM, non-lineer veriler için de uygulanabilir. Bu durumda, verilerin doğrusal olarak ayıramadığı durumlarda kernel fonksiyonları kullanılır. Kernel fonksiyonları, verileri daha yüksek boyutlu uzaylara projekte etmek suretiyle doğrusal olarak ayrılabilir hale getirir. SVM, doğrusal olarak ayıramayan verileri kernel fonksiyonları kullanarak doğrusal olarak ayrılabilir hale getirerek sınıflandırabilir [21].

SVM, sınıflandırma ve regresyon problemlerinde başarılı sonuçlar veren bir algoritmadır. Uygulama alanları arasında görüntü sınıflandırma, metin sınıflandırma, biyoinformatik, finansal analiz ve spam filtreleme gibi birçok alanda kullanılır. SVM, diğer sınıflandırma algoritmalarına göre daha az veriye ihtiyaç duyduğu için veri setlerinin küçültülmesinde de kullanılabilir.

SVM, aynı zamanda outlierlara karşı da oldukça dirençlidir. SVM, sınıflandırma hiperdüzlemi üzerinde bulunan destek vektörleri sayesinde, veri setindeki outlierlar tarafından oluşturulabilecek etkiyi minimize eder.

SVM'nin bir diğer avantajı da, karar sınırlarının net ve yüksek doğrulukla çizilebilmesidir. Bu sayede sınıflandırma işlemi sonucu elde edilen sonuçlar kolayca yorumlanabilir.

SVM, bazı dezavantajlarına da sahiptir. Özellikle, non-lineer veriler için kullanılan kernel fonksiyonlarının doğru bir şekilde ayarlanması gerekmektedir. Kernel fonksiyonunun yanlış seçilmesi veya yanlış ayarlanması, sınıflandırma performansını ciddi şekilde etkileyebilir.

Bunun yanı sıra, SVM, çok büyük veri setleri üzerinde çalışırken hesaplama yükü açısından zorluklar yaşayabilir. SVM'nin hesaplama yükünü azaltmak için birçok optimize edilmiş algoritma ve paralel hesaplama teknikleri geliştirilmiştir.

Sonuç olarak, SVM, veri sınıflandırma problemlerinde oldukça etkili bir makine öğrenmesi algoritmasıdır. Lineer ve non-lineer verileri sınıflandırabilir, outlierlara karşı dirençlidir ve net karar sınırları çizebilir. SVM'nin doğru kernel fonksiyonu ve ayarlarının seçilmesi, performansı etkileyebilir. SVM, uygulama alanı açısından oldukça geniş bir yelpazeye sahiptir ve birçok endüstriyel ve akademik alanda kullanılmaktadır [22].

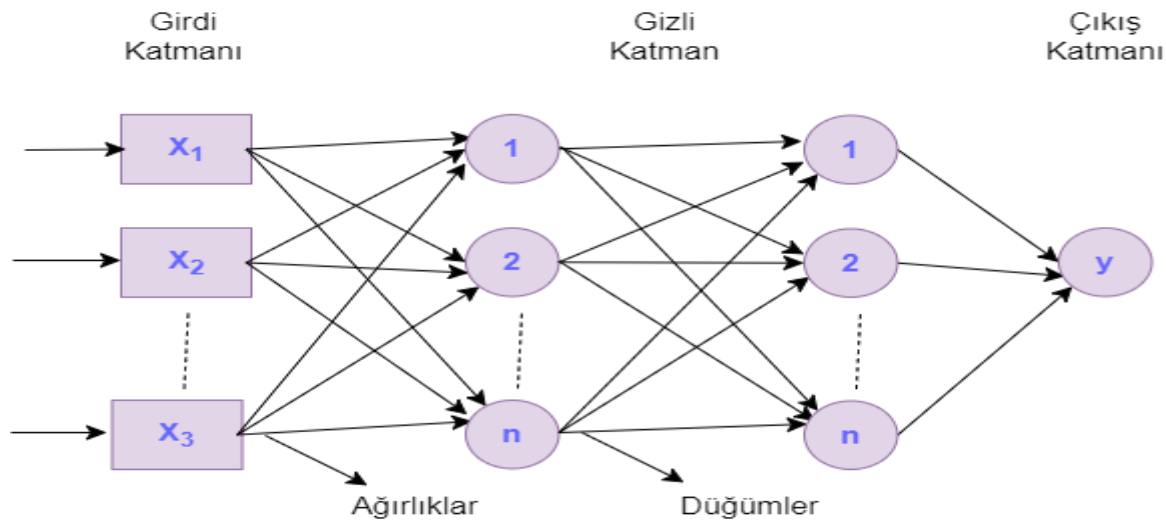
2.3.2. KNN

K-En Yakın Komşu (K-Nearest Neighbors), sınıflandırma ve regresyon problemlerinde kullanılan bir makine öğrenme algoritmasıdır. KNN algoritması, yeni bir örneği sınıflandırmak veya tahmin yapmak için çevresindeki en yakın komşularını kullanır [23].

KNN'nin çalışma prensibi oldukça basittir. Öncelikle, bir eğitim veri seti kullanılarak algoritma eğitilir. Bu eğitim veri setindeki her bir örneğin etiket veya sınıf bilgisiyle ilişkilendirilmesi gerekmektedir. Daha sonra, yeni bir örneğin sınıflandırılması veya tahmin edilmesi gerektiğinde, KNN algoritması bu yeni örneğin çevresindeki en yakın K komşuyu bulur. KNN'nin komşuları bulmak için bir mesafe metriği kullanır. En yaygın olarak kullanılan mesafe metrikleri Euclidean mesafesi ve Manhattan mesafesidir. Örneğin, bir sınıflandırma problemi üzerinde çalışırken, KNN algoritması yeni örneğin çevresindeki en yakın K komşuyu Euclidean mesafesine göre belirleyebilir [24].

KNN algoritması, sınıflandırma problemlerinde çoğunluk sınıfına dayalı bir karar verme mekanizması kullanır. Yani, K en yakın komşunun sınıf etiketlerine bakarak yeni örneği çoğunluk sınıfına atar. Regresyon problemlerinde ise, K en yakın komşunun ortalama değerini kullanarak tahmin yapılabilir [25].

KNN algoritmasının avantajlarından biri, basit bir yapısı olmasıdır. Ayrıca, veriye dayalı karar verme süreçlerinde etkilidir ve yeni veri noktalarına kolayca uyum sağlayabilir. Ancak, KNN'nin dezavantajları da bulunmaktadır. Özellikle büyük veri setleri üzerinde yavaş çalışabilir ve bellek kullanımı yüksek olabilir [26].



Şekil 7 KNN Mimari Yapısı

2.4. DERİN ÖĞRENME

Makine öğreniminin alt dalı olan derin öğrenme mimarisinin kullanımı giderek artmaktadır. Derin öğrenme yöntemleri görüntü işleme; nesne, ses, yüz tanıma gibi birçok alanda kullanılmıştır [27].

Makine öğrenimi ile birlikte popüler yapay zekaya ilgi büyük ölçüde artmıştır. Günümüzde yapay zeka yaygın olarak kullanılır. Bu sebepten dolayı derin öğrenme mimarisinin ortaya çıkmasına neden olmuştur. Derin öğrenme veya yapay zeka, bir bilgisayarın veya bilgisayar kontrollü bir makinenin, akıllı varlıklara benzer mekanizmalar kullanarak karar verme yeteneğidir. Aslında bu karar bir iradeyi temsil etmektedir. Çünkü irade, insanın kendisi için düşünme ve karar verme yeteneğidir. İşte tam da bu yüzden yapay zeka, bilgisayarları insan gibi düşündürüyor. Bir veya daha fazla gizli katmana sahip olan Derin öğrenme, içerisinde Yapay Sinir Ağları ve buna benzer makine öğrenimi algoritmaları içeren bir mimaridir. Diğer bir deyişle, Deri Öğrenme en az bir yapay sinir ağı kullanmaktadır. Bilgisayar, elindeki bilgilerden birkaç algoritma aracılığıyla yeni bilgiler alır [28].

Verinin temsilinden öğrenmeye dayalı olduğu derin öğrenme algoritması bir resim için temsil ifade ediliyorsa bu resmin yoğunluk değerleri, resmin boyutu şekli, arka planı vb. özellikler olarak ifade edilebilir. Bu özelliklerin bazıları veriyi daha iyi temsil ettiği için derin öğrenme algoritması makine öğrenmesinin aksine veriyi elle değil algoritmalar yöntemi ile bu işlemi yapar. Bu işleme de özellik çıkarımı adı verir. Bu algoritmalarından biri de CNN algoritmasıdır. Derin öğrenme mimarisi üzerinde tartışılan 6 mimari yapı vardır ve bunların üzerinde durulmaktadır. Bu mimarilerden ilki ve bu proje de büyük öneme sahip CNN mimarisidir. CNN açılımı Convolutional Neural Networks yani Evrşimli Sinir Ağlarıdır. CNN, derin öğrenme kavramına ait temel bir yapıdadır [29].

2.4.1. DERİN ÖĞRENME KÜTÜPHANELERİ

Derin Öğrenme Alanında Kullanılan Kütüphaneler	Programlama Dili	Ne için kullanılır?
OpenCV	Python	Nesneleri, yüzleri ve hatta insanların el yazılarını tanımlamak için görüntüleri ve videoları işlemek için kullanılabilir. Python, NumPy gibi çeşitli kütüphanelerle entegre, analiz için OpenCV dizi yapısını işleyebilir.
Numpy	Python	Çok boyutlu matrisleri, dizileri destekleyen bu kütüphane Matematiksel işlemler için kullanılan bir Python kütüphanesidir. Bu kütüphanenin açılımı Sayısal Python'dur.
TensorFlow	Python	Makine öğrenmesi için geliştirilmiş bir kütüphane olup Derin Öğrenme mimarisin de kullanılır. Grafikler yardımıyla sayısal hesap yapmamıza yardımcı olmaktadır.
Keras	Python	Sinir ağı kütüphanesi olarak bilinmektedir. Tensorflow, Theano gibi kütüphanelerle üst katman olarak yazılmıştır yani keras bu kütüphanelerle beraber çalışabilir. Derin sinir ağları model geliştirmede büyük avantaj sağlar.
Matplotlib	Python	Matplotlib, Python ve sayısal uzantısı NumPy için platformlar arası, veri görselleştirme ve grafik çizim kitaplığıdır
Os	Python	Python OS modülü, dosyalar ve dizinlerle çalışmamıza izin verir.

Tablo 1 Derin Öğrenme Kütüphaneleri

2.4.2. CNN

CNN mimarisi özellik çıkarımına izin veren bir Derin öğrenme mimarisidir. Yapay Sinir Ağları özellik çıkarımına izin vermezler.

CNN görüntü işleme gibi alanlarda iyi değerler üretir ve performans sonuçları çok yüksek olup çok katmanlı bir sinir ağına dayanır ve özel bir derin öğrenme mimarisine sahiptir.

Bu katmanlar;

Convolutioanl Layer (Evrışim Katmanı)

Non-Linearity Layer (Lineer Olmayan Katman)

PoolingLayer (Havuzlama Katmanı)

Flattening Layer (Düzleştirme Katmanı): Matris halinde olan görseli vektöre dönüştürme işlemini yapan katman

Fully-Connected Layer (Tam Bağlı Katman) [30].

a) Convolutional Layer

CNN'lerin yapı taşı olan bu katman en önemli katmanlardan biridir. Verilen görselin özelliklerini algılamaktan sorumludur. Görseller piksellerden oluşan bir matristir. Her piksel içinde belirli değerler taşır. Bu katman, özellik çıkarımı için görsele filtre uygular. Bu filtreye örnek verilecek olursa kenarları algılayan filtre örnek verilebilir. Bu gibi filtreler çok boyutlu filtrelerdir. Piksel değerlerini içerir. Şekil-1'de kullanılan bir resim piksellere ayrılmıştır. Resmin boyutları 5x5x3 boyutlarında bir matristir. Burada 5 değeri matrisin yüksekliği ve genişliğini 3 ise derinliğini ifade etmektedir.

1	1	1	0	0
0	1	0	0	1
0	1	1	1	0
1	0	0	1	1
0	1	0	1	0

Şekil 8 Kullanılan Görsel

Resmin 5x5 boyutlarında 1 ve 0'lerden oluşan bir matris olarak kabul edelim ve filtremizi 3x3 boyutunda oluşturalım.

0	1	1
0	1	0
1	1	0

Şekil 9 Uygulanan Filtre

5X5 bir matrisin her 3X3'lük kısmına bu filtre 9 kere uygulanıp matris çarpımı yapılıyor sonuç olarak 3X3 yeni bir sonuç matrisi oluşturuluyor.

4	3	2
3	1	3
3	3	3

Şekil 10 Sonuç Matrisi

Sonuç matrisi genellikle Özellik Haritası olarak adlandırılır. Filtre resim üzerinde hareket ettirilir ve her hareketinde matris çarpımı yapılır. Bu sayede özelliklerimizi tespit ederiz. Eğer birden fazla özellik tespit etmek istersek daha fazla filtre uygulamamız gerekir. Bu da bu katmanın CNN ağında fazla kullanmamıza neden olur.

b) Non-Linearity Layer

Bütün evrişim genellikle katmanlarından sonra uygulanan bir katmandır. Doğrusal olmayan katman, genellikle aktivasyon katmanı olarak da adlandırılır. Çünkü bu katman, aktivasyon fonksiyonlarını uygulandığı katmandır. Bu işlevlerden bazıları sigmoid, tanh ve ReLu işlevleridir. Bu işlevler, negatif değerlerin neden olduğu özelliklerin anlaşılabilmesi sorununu çözer. En sık kullanılan fonksiyon ReLu fonksiyonudur.

$f(x) = \max(0, x)$ çalışır. ReLu fonksiyonunun asıl amacı negatif değerlerden kurtulmaktır. ReLu fonksiyonunun Özellik Haritasına uygulandığında aşağıdaki gibi bir sonuç üretilir.




Şekil 11 Non-Linear Katmanının Uygulanışı

Özellik Haritasında ki siyah değerler negatif değerlerdir. Relu fonksiyonu siyah değerlerin yerine 0 değerini koyar.

c) Pooling Layer

Havuzlama katmanı olarak adlandırılan bu katman, evrşim katmanlarının aralarına uygulanan bir katmandır. Bu katmanın görevi, temsilin geçiş boyutunu ve ağdaki parametre ve hesaplama sayısını azaltmaktır. Bu şekilde yakalanan gereksiz özellikler göz ardı edilir ve aynı zamanda işlem gücü azaltılır.

CNN modellerinde genellikle iki farklı pooling tekniği kullanılır. En yaygın olarak kullanılanı max pooling'dir. Yine benzer çalışan average poolingdir. Avarage pooling değerlerin ortalamasını alırken Max pooling maksimum değerleri alır.




Şekil 12 Maxpooling İşlemi

d) Flatting Layer

Son katman olan bu katmanın görevi Tam bağlı katmanın girişindeki verileri hazırlamaktır. Convolution ve pooling işlemlerinden sonra oluşan matrisleri n satır 1 sütundan oluşan


vektörlere dönüştürme işlemine denir. Bu vektör Artificial Neural Network(Yapay Sinir Ağı) inputu olacaktır.



Şekil 13 Flatting İşlemi

e) Fully-Connected Layer

Artificial Neural Network olduğu katmandır. Tam bağlantılı katman demektir ve ConvNet'in son ve en önemli katmanlardan biridir. Verilerin sinir ağı yoluyla öğrenme işleminin gerçekleştiği katmandır.



Şekil 14 Fully-Connected İşlemi

AlexNet, LeNet, ZFNet, VGGNet, GoogLeNet, ResNet gibi modeller CNN mimarisi modelleri olarak adlandırılmaktadır LeNet ile başlayıp her model bir önceki modele göre gelişerek devam etmiştir. Derin öğrenmenin anlaşılmasında ve geliştirilmesinde büyük bir rol oynamıştır [31].


CNN de Derin Öğrenme;

CNN, görüntüleri girdi olarak alan, görüntü işlemede yaygın olarak kullanılan bir derin öğrenme algoritmasıdır. Görsel özelliklerin özelliklerini (features) farklı işlemlerle yakalayıp sınıflandıran bu algoritma farklı katmanlardan oluşmaktadır [32].

2.4.2.1. LE NET

LeNet-5, ilk olarak 1998 yılında yayınlanmış olan ve görüntü tanıma için kullanılan evrişimli sinir ağı modelidir. Rakam tanıma için kullanılan en eski CNN modelidir. Posta numaraları, banka çekleri üzerindeki sayıların okunması için Yann LeCun ve ekibi tarafından geliştirilen bir modeldir. Dolayısıyla bu ağı, Bugün gördüğümüz modern ağların çoğu için bir tür şablon görevi görmektedir [33].

Le Net mimarisi Fully-Connected Layer, RuLu Layer, Pooling Layer, Softmax Layer oluşmaktadır. Softmax Layer sınıflandırma katmanı olarak adlandırılır. Kendisinden önce gelen tamamen bağlı katmandan inputu alır ve sınıflandırma yapmak için kullanır [34].



Şekil 15 Le Net Mimari Yapısı

Bu ağı girdi olarak 32x32 boyutlarında bir görüntü alır. (32 cross 32 images). İlk katman 5'e 5 evrişime sahipti ve sıfır dolgusu yoktu bu da 28 cross 28 output ve ardından 2'e 2 pooling'e yol açar.

Bu pooling average pooling işlemidir. Yani average pooling temel olarak çıktı, filtrenin o 2'e 2 alandaki dört ögenin ortalamasıdır. Ardından 5'e 5, 5 çapraz kırılım gelir yine dolgu yoktur. 10'a 10 çıktıya yol açar ve ardından 5'e 5 evrişim verir ve ardından 16 çapraz 5 çapraz 5 haritaya yol açar bir maxpooling sağlar.

Bu haritaların üzerinde 5'e 5'lik bir mahkumiyet sağladıklarında temelde tamamen bağlantılı bir katman yapmakla aynıdır. Ancak bu katmana evrişim katmanı diyorlar. 121 çapraz 1 çıktıya yol açan 5 konvolüsyon bu ilginç bir kısımdır. Yani 32x32'den büyük bir girdimiz varsa, bu

katmanlardaki özellik haritalarının sayısı bu katmandaki özellik haritalarının boyutu 1'den büyük olur çarpı bir aslında 64 çapraz 64 giriş diyelim tüm ağı 32'lik bir adımla 64 ça64 boyunca adım adım ilerleyebileceğimiz ve aslında burada 4 2 çapraz 2 çıktı alabileceğimizdir. Bu yüzden yol sonra nihayet tamamen bağlı katmana ve ardından karar katmanına veya çıktı katmanına, isterseniz burada softmax de kullanabilirsiniz.

Sonuç olarak bu ağ mevcut ağlarda şu anda bile tekrarlanan birkaç şeye sahiptir. Birincisi girdiden başlayarak ağın derinlerine indikçe, özellik haritalarının boyutunun, aslında alt örnekleme işlemi olan havuzlama işlemi tarafından da konvolüsyonlar nedeniyle tipik olarak küçülmesidir.

Sadece özellik haritalarının boyutunu azaltmakla kalmaz, özellik haritalarının sayısını artırır. Böylece 121 çapraz 1 özellik haritamız olur ve ilk katmanda 28'e 28 boyutunda yaklaşık 6(cro) 6 özellikli haritamız olur [35].

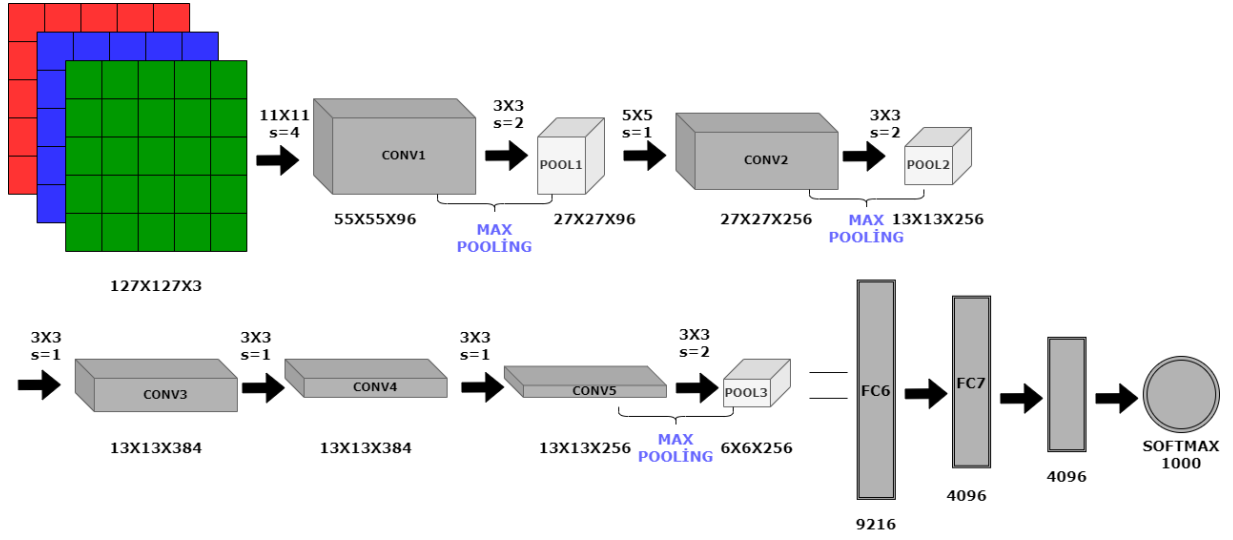
2.4.2.2. ALEX NET

AlexNet CNN modeli, 2012 ImageNet Büyük Ölçekli Görsel Tanıma Yarışması'nı büyük bir farkla kazandı. Bu model Krizhevsky, Sutskever ve Hinton tarafından geliştirilmiş [36].

Bu mimaride tahn fonksiyonu yerine ReLu fonksiyonu tercih edilmiştir. Çünkü ReLu fonksiyonu daha hızlıdır ve eğitim süresini azaltır. Eğitim süresini azaltmak ve aşırı öğrenmeyi önlemek için de Dropout katmanı kullanılmıştır. Dropout katmanı ezber yapan düğümleri ortadan kaldırarak bu durumun önüne geçer. 25 katmanlı CNN kullanan Alex Net mimarisinde 5 evrişim katmanı bulunmaktadır. Her evrişim katmanından sonra ReLu katmanı kullanılmaktadır. Input Layer, Normalization Layer, Pooling Layer, Dropout Layer, Full-Connected Layer, SoftMax Layer ve Output Layer'dan oluşmaktadır. Normalization Layer; Nöronların aktivasyonunu normolize ederek eğitim süresini azaltır. Geri beslemeli ağlarda gizli katanlardaki durumu normalleştirmede kullanılır. Daha çok ReLu katmanından sonra kullanılır [37].

AlexNet ağına giriş, 227 x 227 boyutunda bir RGB görüntüsüdür, dolayısıyla 3 farklı kanalı vardır. Bu kanallar; kırmızı, yeşil ve mavi.

Daha sonra AlexNet'te, her biri 11 x 11 boyutunda ve adım sayısı 4'e eşit olan 96 farklı çekirdeğe sahip ilk evrişimli katman vardır. Böylece, ilk evrişimli katmanın çıktısı size 96 farklı kanal veya özellik haritası verir çünkü 96 farklı çekirdek vardır ve her bir özellik haritası 55 x 55 boyutunda özellikler içerir [38].




Şekil 16 Alex Net'in Temel Mimarisi

2.4.2.3. VGG NET


Oxford tarafından sunulan bir mimaridir. VGG-16 mimarisi yüksek kernel boyutlarını Alex Net mimarisine göre daha çok azaltmıştır. Alex Net mimarisinde kernel boyutları 11 ile başlayıp 5 ve 3 diye devam ediyordu yani boyutlar sabit değildi ama VGG-16 mimarisi bu boyutları sabit yapmıştır. VGG-16 evrişim katmanı ve tam bağlı katman sayısı toplam 16'dır. VGG-19 versiyonu da vardır. Bu iki versiyon arasındaki fark katman sayılarının farklı olmasıdır.

VGG-16 mimarisi toplam 21 katmandan oluşmaktadır. Evrişim Katmanı, Havuzlama Katmanı ve Tamamen Bağlı Katmanlardan oluşan bu mimari artan bir ağ yapısına sahip olan bir mimaridir. Girdi görüntüsü 224x224 piksel boyutlarındadır. Evrişim katmanında uygulanan filtre 3x3 piksel boyutlarındadır. Son katman olan Tamamen Bağlı Katman özellik çıkarımı için kullanılmaktadır.



Şekil 17 VGG-16 Mimari Yapısı

VGG-19 mimarisi VGG-16 Net mimarisinden katman sayısı olarak farklıdır. VGG-19 mimarisinde toplamda 24 katman vardır. Bu katmanlar Evrişim Katmanı, Havuzlama Katmanı, Tamamen Bağlı Katmandır. 16 evrişimi katmanı, 5 havuzlama katmanı ve 3 tamamen bağlı katmandan oluşmaktadır. VGG-16 artan bir ağ yapısına sahipken VGG-19 derinlemesine bir ağ yapısına sahiptir. Parametre sayısını azaltmak amacıyla evrişim katmanına 3x3 boyutlarında bir filtre uygulanır. 138 milyon parametre içerir [39].



Şekil 18 VGG-19 Mimari Yapısı

2.4.2.4. RES NET

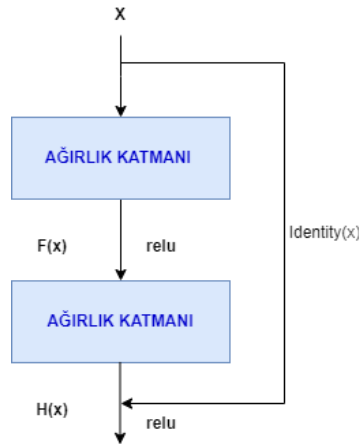
AlexNet modelinden sonra ImageNet yarışmasını kazanan CNN tabanlı bir mimaridir. Ağ derinliği arttıkça, doğruluğun doyuma ulaştığını ve sonra hızla düştüğünü gözlemlediler. Ağ, skip connection adı verilen yeni bir yaklaşma yolundan oluşur. Bu bağlantılar, verilerin ve

gradyanların akması için alternatif bir yol sağlar ve eğitimi mümkün kılar. Bu bağlantı modeli, VGG'den daha az karmaşık olmakla birlikte 152 katmanlı eğitim ağına yardımcı olur.

Artık ağların temel fikri:

Derin olmayan ağdaki ağırlıkları kopyalayarak ve daha derin ağdaki diğer katmanları kimlik eşlemesi olacak şekilde ayarlayarak, derin olmayan bir ağdan daha derin bir ağ yapılabilir.

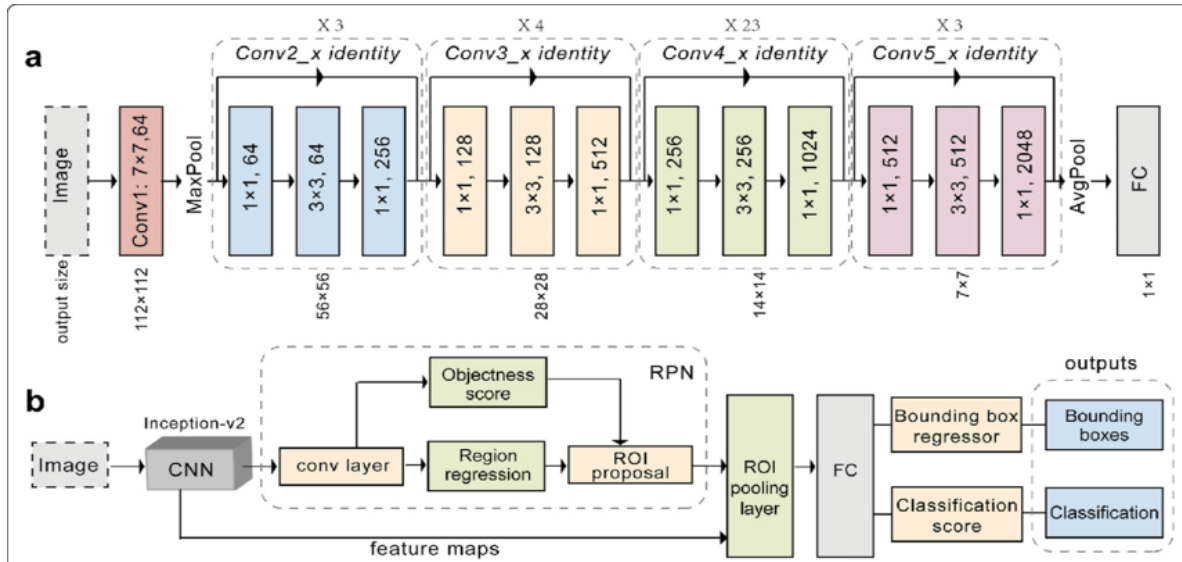
Bu formülasyon, daha derin modelin derin olmayan muadilinden daha yüksek eğitim hatası üretmemesi gerektiğini gösterir.



Şekil 19 Artık Bloğu

Toplamaya x katmanı girdisini taşıyan düz çizgi artık bloğu olarak adlandırılmaktadır. Bir veya daha fazla katmanı atlayan bağlantılara kısayol bağlantıları denir. Artık katmanlar arasında kalan bloklar ve girdiler bağlantılar üzerinden daha hızlı yayılabilir. Kısayol bağlantısını kullanmadan önce, x girdimiz katmanın ağırlıkları ile çarpılır ve bir ön yargı terimi eklenir. Sonra aktivasyon fonksiyonundan geçiyoruz ve çıktıyı $H(x)$ olarak alıyoruz.

$H(x)=F(x)+x$ denklemi oluşur [40].



Şekil 20 ResNet Mimari Yapısı

2.4.3. LSTM

Tabanlı öğrenmenin bir alt kümesi olan derin öğrenme, son yıllarda birçok makine öğrenmesi uygulamasında büyük bir başarı sağlamıştır. Derin öğrenmenin alt alanlarından biri olan Rekurrent Sinir Ağları (RNN), zaman serileri, doğal dil işleme, görüntü işleme ve ses işleme gibi birçok alanda kullanılmaktadır. RNN'lerin bir türü olan LSTM (Long Short-Term Memory), özellikle zaman serisi verilerinin işlenmesinde ve doğal dil işleme uygulamalarında başarılı sonuçlar vermektedir.

LSTM, geleneksel RNN'lere kıyasla daha uzun vadeli bağımlılıkları ele alabilen ve bu bağımlılıkları daha doğru bir şekilde modelleyebilen bir yapıya sahiptir. Bu sayede, uzun dönem bağımlılıkların önemli olduğu problemlerde daha etkili sonuçlar elde edilir.

LSTM'nin temel yapısı, bir hücre ve üç adet kapıdan oluşur: unutma kapısı, giriş kapısı ve çıkış kapısı. Hücre, geçmiş bilgiyi saklamak için kullanılır ve kapılar, hangi bilgilerin hücreye ekleneceği ve hangi bilgilerin atılacağına karar verir. Unutma kapısı, hücrenin içindeki bilgilerin ne kadarının atılacağına karar verirken, giriş kapısı, yeni bilgilerin hücreye ne kadar ekleneceğini belirler. Çıkış kapısı ise, hücrenin içindeki bilgilerin ne kadarının kullanılacağına karar verir [41].

LSTM, doğal dil işleme uygulamalarında oldukça popülerdir. Özellikle, metin sınıflandırma, dil modelleri, çeviri ve kelime öğrenme gibi birçok alanda kullanılır. LSTM, kelime dizilerinin sıralı bir şekilde işlenmesinde oldukça başarılıdır. Örneğin, bir cümleyi analiz ederken, bir kelimenin anlamı, cümledeki diğer kelimelerle birlikte değerlendirilmelidir. LSTM, bu tür

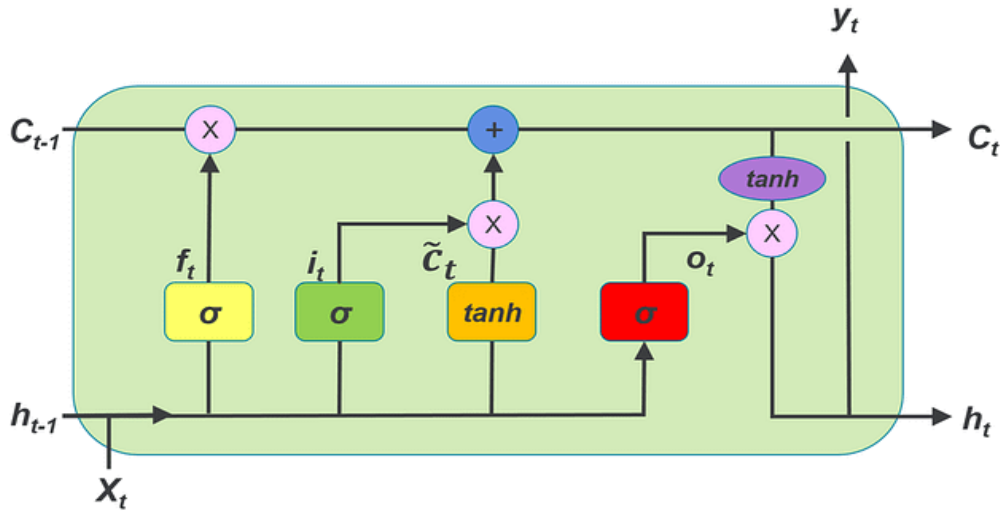
durumlarda, kelime sırasını dikkate alarak, cümlenin anlamını daha iyi anlamamıza yardımcı olur [42].

LSTM, zaman serisi verilerinin işlenmesinde de oldukça etkilidir. Örneğin, finansal piyasa verilerinin analizi gibi uygulamalarda, bir hissenin fiyatı, önceki günlerdeki fiyatlarla ve piyasa trendleriyle bağlantılıdır. LSTM, bu tür verileri analiz ederek, gelecekteki fiyat hareketlerini tahmin etmemize yardımcı olabilir.

LSTM'nin dezavantajlarından biri, oldukça yüksek hesaplama maliyetidir. LSTM, yoğun hesaplama gerektiren bir ağıdır ve büyük veri kümelerinde çalıştığında zaman ve kaynak tüketimi açısından zorlu olabilir. Bununla birlikte, günümüzde yüksek performanslı donanımların ve paralel hesaplama tekniklerinin geliştirilmesiyle bu dezavantaj azalmaktadır [43].

LSTM'nin bir diğer dezavantajı, aşırı öğrenme (overfitting) sorunudur. Aşırı öğrenme, modelin eğitim verilerine aşırı uyum sağlaması ve yeni veriler üzerinde kötü sonuçlar vermesidir. Bu sorunu önlemek için, eğitim verilerinin düzenlenmesi, veri ön işleme tekniklerinin kullanılması ve modelin düzenlenmesi gibi yöntemler kullanılabilir.

LSTM, doğal dil işleme ve zaman serisi verileri analizi gibi birçok uygulamada başarılı sonuçlar vermektedir. Ancak, yüksek hesaplama maliyeti ve aşırı öğrenme sorunu gibi dezavantajları da vardır. LSTM'nin performansını artırmak için, daha fazla veri, daha iyi veri ön işleme teknikleri, daha iyi hiperparametre ayarı ve daha iyi model optimizasyon teknikleri kullanılabilir [44].



Şekil 21 LSTM Yapısı

3. DENEYSEL SONUÇLAR

3.1. MODEL VE YÖNTEMLER

Bu çalışmada, makine öğrenimi yöntemleri ve derin öğrenme yöntemleri kullanılarak hibrit modeller test edilmiştir. İki farklı veri seti olan Malaria veri seti ve M-nist veri seti üzerinde deneyler gerçekleştirilmiştir.

Bu deneylerde, CNN-LSTM, CNN-SVM ve CNN-KNN hibrit modelleri kullanılmış ve bu modellerin performansları karşılaştırılmıştır. Malaria veri seti ve M-nist veri seti, farklı özelliklere sahip olduğu için bu iki veri seti üzerinde ayrı ayrı test edilmiştir.

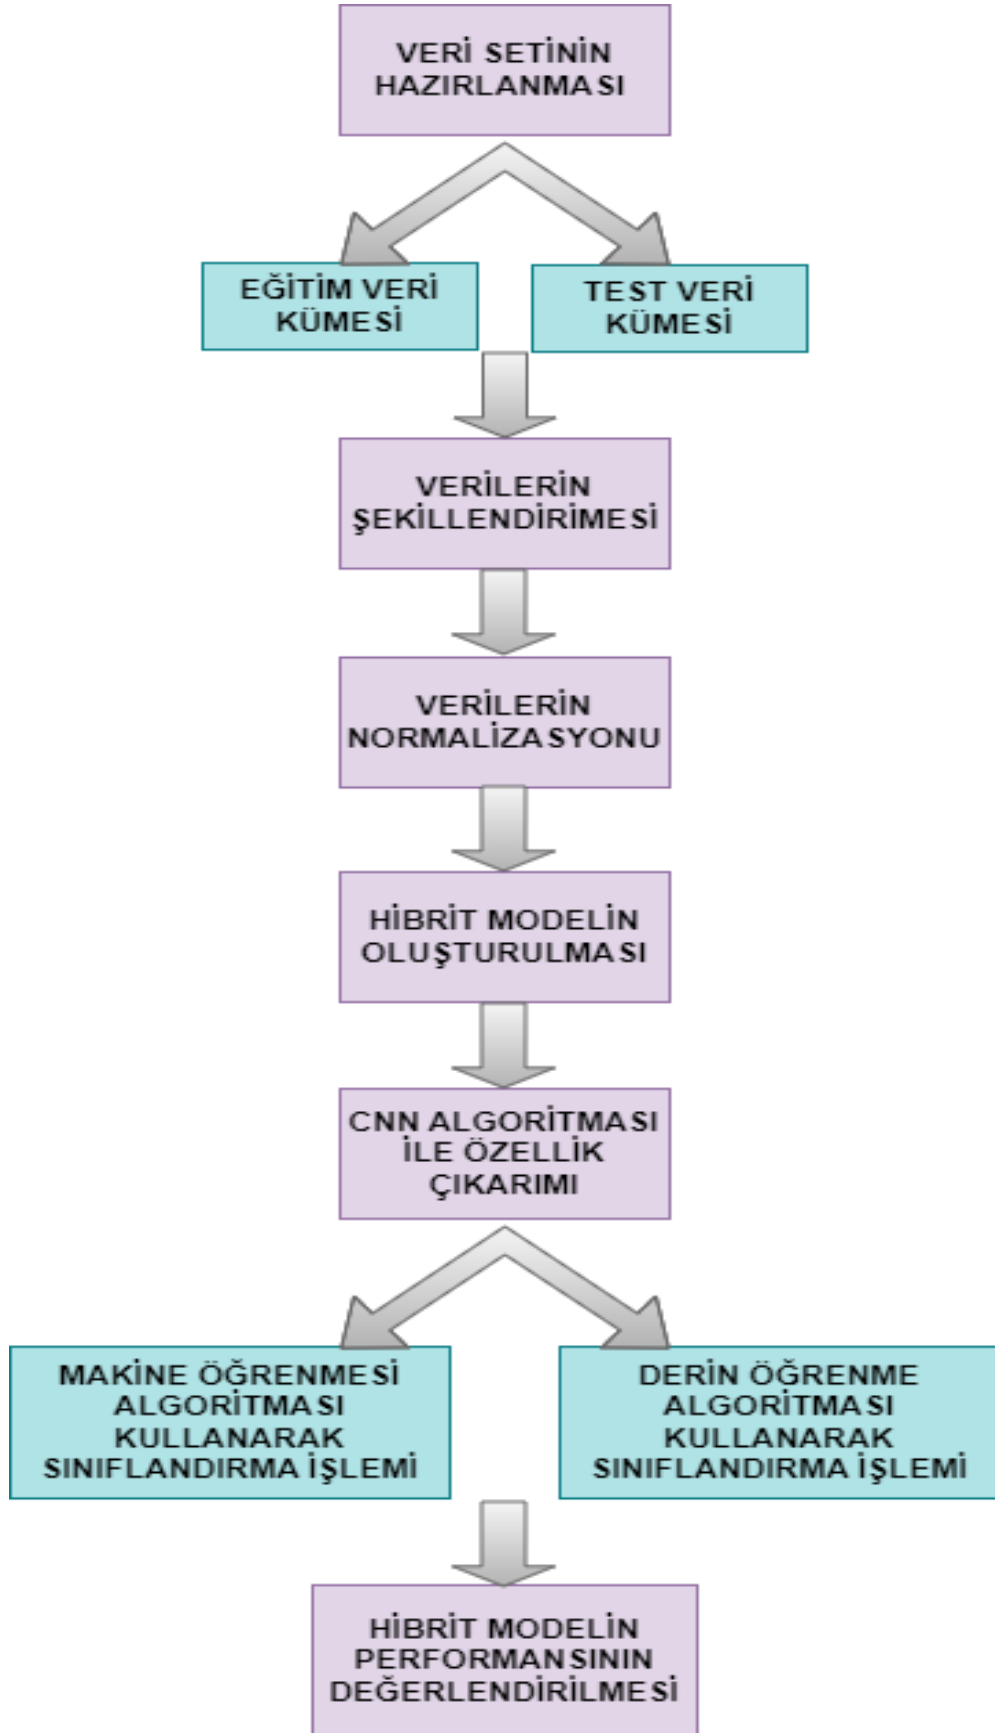
Sonuçlar, hibrit modellerin her iki veri setinde de iyi performans gösterdiğini göstermektedir. CNN-LSTM, CNN-SVM ve CNN-KNN modellerinin her ikisi de iyi sonuçlar vermiştir, ancak performansları arasında bazı farklılıklar bulunmuştur. Her bir modelin avantajları ve dezavantajları göz önüne alınarak, hangi modelin hangi veri setinde daha iyi performans gösterdiği belirlenebilir.

Bu çalışma, hibrit modellerin kullanılmasının, makine öğrenimi ve derin öğrenme alanında farklı veri setleri üzerindeki performansını anlamak için önemli bir adımdır. Hibrit modellerin kullanılması, farklı özellikleri bir araya getirerek daha iyi bir sınıflandırma veya tahmin performansı elde etmeyi sağlayabilir. Çalışmada Google Colab ortamı kullanılmıştır. Colab, bulut tabanlı bir Jupyter Notebook hizmetidir ve bu çalışma için ideal bir platform oldu.

Colab'ın sunduğu interaktif kod yazma ve çalıştırma imkanları sayesinde veri analizi ve model eğitimi işlemlerimi kolaylıkla gerçekleştirildi. Python programlama dilini destekleyen Colab, gelişmiş kütüphaneleri önceden yüklemesiyle zaman kazandırdı.

Ayrıca, Colab'ın GPU ve TPU gibi donanım hızlandırıcılarına erişim imkanı, makine öğrenimi modellerimin daha hızlı eğitilmesine ve performansının artmasına yardımcı oldu. Bu da çalışmada elde ettiğim sonuçların daha sağlam ve güvenilir olmasını sağladı.

Sonuç olarak, Colab ortamı, bu çalışmada analiz süreçlerini kolaylaştırmak için mükemmel bir araç oldu. Veri analizi, model eğitimi ve işbirliği özellikleri, çalışmada elde ettiğim sonuçları geliştirmede yardımcı oldu ve çalışmamın daha güçlü bir temele dayanmasını sağladı.



Şekil 22 Proje Akış Şeması

3.1.1. CNN-LSTM

CNN-LSTM hibrit modeli, özellikle zaman serisi verilerindeki mekansal özellikleri çıkarmak ve zaman bağımlılıklarını modellemek için kullanılır. CNN, verinin mekansal özelliklerini çıkarmak için kullanılırken, LSTM, zaman serisi içerisindeki bağımlılıkları modellemek için kullanılır. Bu şekilde, model hem verinin mekansal özelliklerini yakalayabilir hem de zaman içindeki değişimleri anlayabilir.

Bu hibrit model, bir görüntü sınıflandırma modeli oluşturmayı amaçlar. Model, evrişimli (convolutional) katmanlar ve bir LSTM (Uzun-Kısa Süreli Bellek) katmanı içerir. Model, verilen görüntüleri sınıflandırmak için eğitilir ve ardından test veri seti üzerinde değerlendirilir. Amacı, karmaşık veri yapıları olan görüntüler üzerinde CNN ve LSTM gibi güçlü derin öğrenme tekniklerini kullanarak sınıflandırma yapmayı hedeflemektedir.

3.1.2. CNN-KNN

CNN-KNN hibrit modeli, CNN'in derin öğrenme yeteneklerini kullanarak verilerden özelliklerin çıkarılmasını sağlar. Daha sonra, bu özellikler KNN algoritmasına giriş olarak verilir ve sınıflandırma veya benzerlik ölçümü yapılır. CNN'in öğrendiği özellikler, KNN'in sınıflandırma performansını artırmak için kullanılır.

Bu hibrit model, önce bir Evrişimli Sinir Ağı (Convolutional Neural Network - CNN) modeli oluşturur ve eğitir. Ardından, CNN'nin özelliklerini çıkarır ve bu özellikleri kullanarak bir K-En Yakın Komşu (K-Nearest Neighbors - KNN) modeli oluşturur ve eğitir. Son olarak, KNN modelini değerlendirir.

3.1.3. CNN-SVM

NN-SVM hibrit modeli, bir derin öğrenme modeli olan Evrişimli Sinir Ağı (Convolutional Neural Network - CNN) ile bir geleneksel makine öğrenimi modeli olan Destek Vektör Makineleri (Support Vector Machines - SVM) arasında bir birleştirme yaklaşımını ifade eder. Bu hibrit model, CNN'in özellik çıkarım yeteneklerini kullanarak verileri işlerken, SVM'in sınıflandırma ve regresyon görevlerindeki etkinliğini sağlamak için kullanılır. CNN-SVM hibrit modelinde, CNN öncelikle veri üzerinde özellik çıkarımı yapar.

Bu işlem, verinin özniteliklerini vektör formunda temsil eden özellik haritaları veya öznitelikler çıkartır. Elde edilen özellikler daha sonra SVM'e giriş olarak verilir. SVM, özellik vektörlerini kullanarak sınıflandırma veya regresyon işlemlerini gerçekleştirir. Bu hibrit modelin avantajlarından biri, CNN'in evrişim ve havuzlama katmanları aracılığıyla verilerin

özelliklerini otomatik olarak öğrenebilmesidir. Bu, verilerin daha karmaşık yapılarını tanıyabilen ve daha soyut özellikler elde edebilen bir derin öğrenme modeline sahip olmayı sağlar. SVM ise, özellik vektörlerini kullanarak doğrusal veya non-lineer olarak ayırıştırma yapabilen bir sınıflandırma veya regresyon modeli sağlar.

4. SONUÇ

Bu çalışmada, CNN-LSTM, CNN-KNN ve CNN-SVM gibi hibrit modellerin performansını değerlendirdik. Hibrit modeller, derin öğrenme ve geleneksel makine öğrenimi yöntemlerinin birleşimiyle daha etkili sonuçlar elde etmek için kullanılan bir yaklaşımdır.

Yapılan deneylerde, farklı veri setleri üzerinde hibrit modelleri eğittik ve performanslarını değerlendirdik.

Sonuçlarımız, hibrit modellerin tek başına CNN veya diğer geleneksel makine öğrenimi modellerinden daha iyi performans gösterdiğini gösterdi. Özellikle, CNN-LSTM modeli zaman serisi verileri üzerinde daha iyi bir performans gösterirken, CNN-KNN ve CNN-SVM modelleri görüntü sınıflandırma görevlerinde daha etkili olduğunu gösterdi.

Ayrıca, hibrit modellerin, derin öğrenme ve geleneksel makine öğrenimi yöntemlerinin avantajlarını birleştirerek daha kapsamlı bir özellik çıkarımı ve sınıflandırma yeteneği sağladığını gözlemledik. Bu, veri setlerindeki karmaşıklığı daha iyi ele almayı ve daha yüksek doğruluk oranları elde etmeyi mümkün kılmaktadır.

Ancak, performans sonuçlarına dayanarak, her bir hibrit modelin veri setine ve görevine bağlı olarak farklı performanslar gösterdiğini belirtmek önemlidir. Optimal sonuçları elde etmek için model seçimi ve hiperparametre ayarlamaları gibi faktörlerin dikkatlice değerlendirilmesi gerekmektedir.

Sonuç olarak, bu çalışma hibrit model kullanımının, farklı veri setleri ve görevler için daha etkili bir sınıflandırma çözümü sağlayabileceğini göstermiştir. Hibrit model seçimine ve uygun hiperparametre ayarlamalarına dikkat edilerek, daha ileri çalışmalarda performansı dahada geliştirilebilir ve farklı uygulama alanlarına uyarlanabilir.


4.1. M-NSİT VERİ SETİ İÇİN CNN-LSTM K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI

Bu çalışmada, K-katlı çapraz doğrulama yöntemi kullanılarak bir sınıflandırma modeli değerlendirildi. Veri seti, 10 farklı sınıfa ait örneklerden oluşuyor. Model, eğitim veri seti üzerinde eğitildi ve ardından test veri seti üzerinde performansı değerlendirildi.

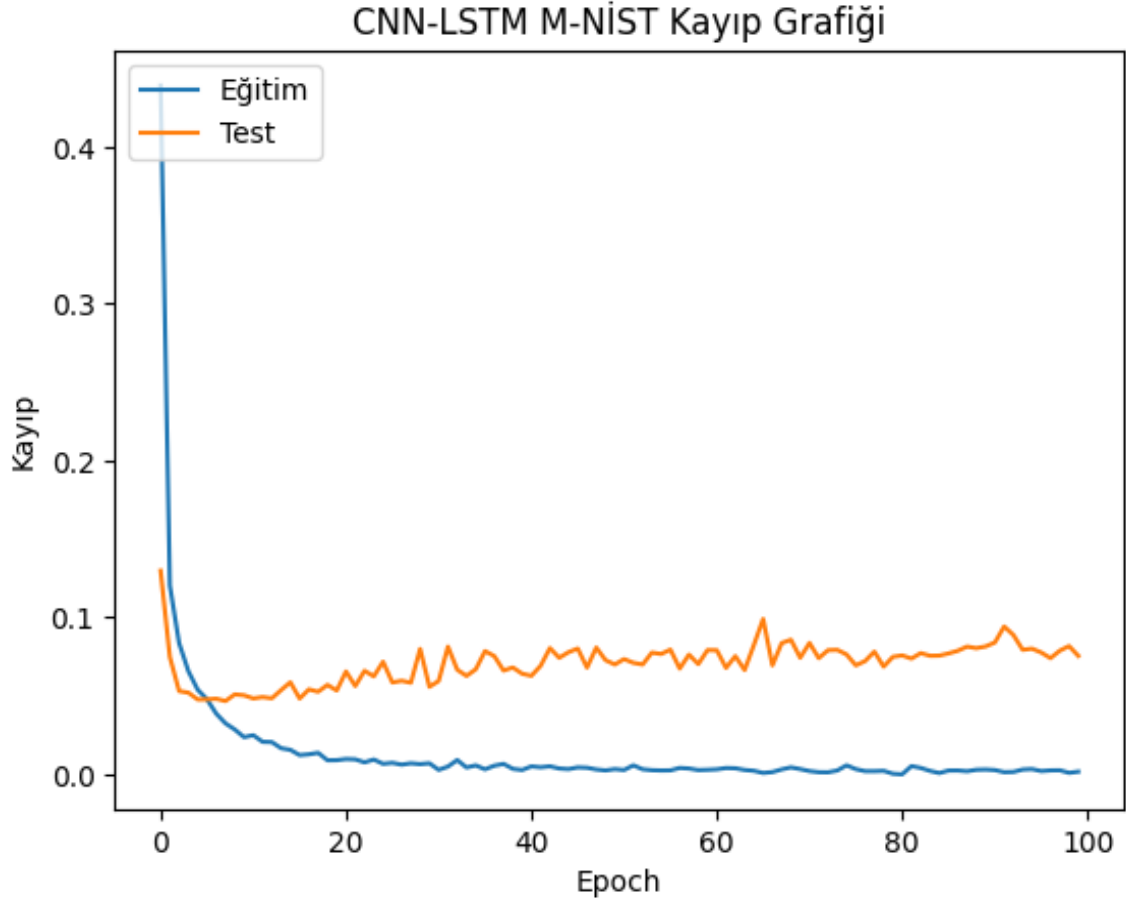
K-katlı çapraz doğrulama sonuçları, modelin performansını objektif bir şekilde değerlendirmemizi sağladı. Her bir katlamada, modelin eğitim ve test doğruluk değerleri kaydedildi. Elde edilen doğruluk değerlerinin ortalaması alındığında, modelin genel doğruluk oranı yüzde 95'in üzerinde oldu. Bu sonuçlar, modelin sınıflandırma görevini başarılı bir şekilde yerine getirdiğini göstermektedir.

4.1.1. DOĞRULUK DEĞERLERİ

Eğitim süreci boyunca, doğruluk ve kayıp değerlerini takip edildi. Aşağıda, eğitim ve test doğruluk değerlerinin epoch sayısına bağlı olarak nasıl değiştiğini gösteren grafikler yer alıyor.



Şekil 23 CNN-LSTM M-NSİT DOĞRULUK GRAFİĞİ




Şekil 24 CNN-LSTM M-NİST KAYIP GRAFİĞİ

Eğitim ve test veri setleri üzerindeki doğruluk değerlerini hesapladık. Eğitim veri setindeki doğruluk değeri 0.9994833469390869, test veri setindeki doğruluk değeri ise 0.9904000163078308 olarak hesaplandı. Bu sonuçlar, modelin eğitim ve test veri setlerinde iyi bir performans sergilediğini göstermektedir.

4.1.2. CONFUSION MATRIX

Confusion matrix, her bir sınıfın tahminlerini gerçek değerlerle karşılaştırmamıza olanak tanıyan bir matristir. Elde edilen sonuçlar, modelin sınıfları doğru bir şekilde ayırt ettiğini ve yanlış tahminlerin de genellikle düşük olduğunu gösterdi.



Şekil 25 CNN-LSTM MNİST Veri Seti Kullanarak Oluşturulan Confusion Matrix

4.1.3. SINIFLANDIRMA RAPORU

Sınıflandırma raporu, sınıflandırma modelinin her bir sınıf için hassasiyet (precision), duyarlılık (recall) ve F1 skoru gibi performans metriklerini sunar. Ayrıca, toplam doğruluk (accuracy) ve makro ve ağırlıklı ortalamalar gibi genel performans ölçümlerini de verir.

Bu sınıflandırma raporuna göre, modelimizin genel doğruluk oranı (%99) oldukça yüksektir. Ayrıca, her bir sınıf için yüksek hassasiyet, duyarlılık ve F1 skorları elde edilmiştir.

Genel olarak, tüm sınıflar için yüksek hassasiyet, duyarlılık ve F1 skorlarına sahip olduğumuz görülmektedir. Bu, modelin her bir sınıfı doğru bir şekilde sınıflandırmada başarılı olduğunu gösterir.

Sonuç olarak, bu sınıflandırma raporu, modelin her bir sınıf için ayrı ayrı başarısını değerlendirmemize ve modelin gücü ve zayıf noktaları hakkında bilgi sahibi olmamıza yardımcı olur.

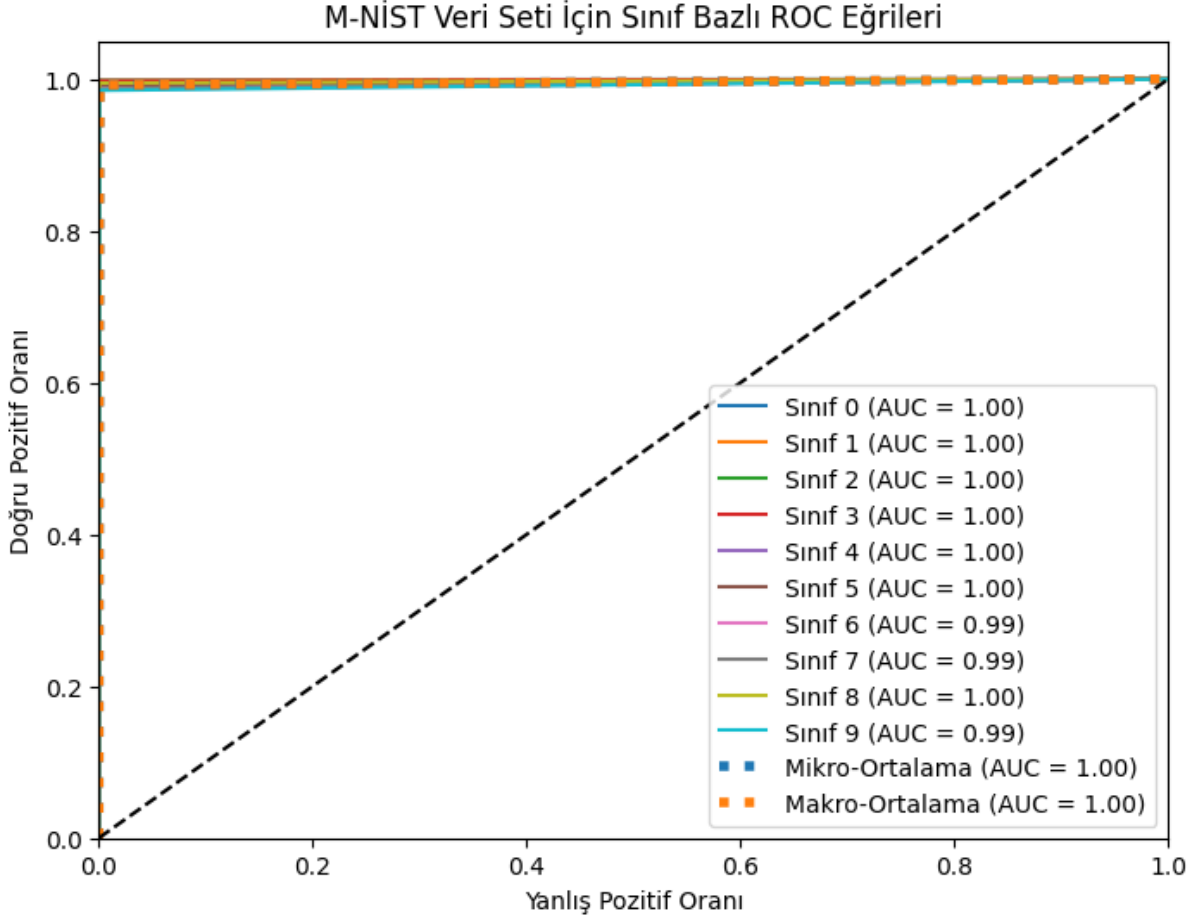
Sınıflandırma Raporu:				
	precision	recall	f1-score	support
0	0.99	1.00	0.99	980
1	0.99	1.00	1.00	1135
2	0.99	0.98	0.99	1032
3	1.00	0.99	0.99	1010
4	0.99	0.99	0.99	982
5	0.99	0.99	0.99	892
6	1.00	0.99	0.99	958
7	0.98	0.99	0.98	1028
8	0.99	0.99	0.99	974
9	0.99	0.98	0.99	1009
accuracy			0.99	10000
macro avg	0.99	0.99	0.99	10000
weighted avg	0.99	0.99	0.99	10000

Şekil 26 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-LSTM Sınıflandırma Raporu

4.1.4. ROC EĞRİSİ VE AUC SKORU

Bu modelde elde edilen Mikro-Ortalama AUC skoru 0.9996'dır. Bu, modelin sınıf tahminlerinin genel olarak yüksek doğruluğa ve başarıya sahip olduğunu gösterir. Yüksek bir Mikro-Ortalama AUC skoru, modelin yanlış pozitif oranını düşük tuttuğunu ve aynı zamanda doğru pozitif oranını yüksek tuttuğunu gösterir. Makro-Ortalama AUC skoru 0.9996'dır. Bu da tüm sınıfların performansının yüksek olduğunu ve modelin genel olarak çok iyi bir sınıflandırma yeteneğine sahip olduğunu gösterir.

Bu değerler, modelin sınıfları doğru bir şekilde tahmin etmedeki yeteneğini ölçmek için ROC eğrileri ve AUC skoru gibi önemli ölçütleri kullandığını gösterir.



Şekil 27 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-LSTM Sınıf Bazlı ROC Eğrileri


4.2. MALARİA VERİ SETİ İÇİN CNN-LSTM K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI

Bu çalışmada, K-katlı çapraz doğrulama yöntemi kullanılarak bir sınıflandırma modeli değerlendirildi. Veri seti, 2 farklı sınıfa ait örneklerden oluşuyor. Model, eğitim veri seti üzerinde eğitildi ve ardından test veri seti üzerinde performansı değerlendirildi.


K-katlı çapraz doğrulama sonuçları, modelin performansını objektif bir şekilde değerlendirmemizi sağladı. Her bir katlamada, modelin eğitim ve test doğruluk değerleri kaydedildi. Elde edilen doğruluk değerlerinin ortalaması alındığında, modelin genel doğruluk oranı yüzde 95'in üzerinde oldu. Bu sonuçlar, modelin sınıflandırma görevini başarılı bir şekilde yerine getirdiğini göstermektedir.

4.2.1. DOĞRULUK DEĞERLERİ

Eğitim süreci boyunca, doğruluk ve kayıp değerlerini takip edildi. Aşağıda, eğitim ve test doğruluk değerlerinin epoch sayısına bağlı olarak nasıl değiştiğini gösteren grafikler yer alıyor.



Şekil 28 CNN-LSTM MALARİA DOĞRULUK GRAFİĞİ




Şekil 29 CNN-LSTM MALARİA KAYIPGRAFIĞI

Eğitim ve test veri setleri üzerindeki doğruluk değerlerini hesapladık. Eğitim veri setindeki doğruluk değeri 0.9984, test veri setindeki doğruluk değeri ise 0.9551805257797241 olarak hesaplandı. Bu sonuçlar, modelin eğitim ve test veri setlerinde iyi bir performans sergilediğini göstermektedir.

4.2.2. CONFUSION MATRIX

Modelin performansını değerlendirmek için confusion matrix kullanıldı. Elde edilen sonuçlar aşağıdaki gibi görülmektedir.

Bu sonuçlara göre, model 2598 pozitif örneği doğru şekilde tahmin etmişken 114 pozitif örneği yanlış şekilde tahmin etmiştir. Benzer şekilde, 133 negatif örneği yanlış şekilde tahmin etmişken 2666 negatif örneği doğru şekilde tahmin etmiştir.



Şekil 30 CNN-LSTM Malaria Veri Seti Kullanarak Oluşturulan Confusion Matrix

4.2.3. SINIFLANDIRMA RAPORU

Modelin performansını değerlendirmek için sınıflandırma raporu kullanılmıştır. Rapor, modelin her bir sınıf için kesinlik (precision), duyarlılık (recall) ve F1-skorunu göstermektedir. Ayrıca, doğruluk (accuracy), makro-ortalama (macro avg) ve ağırlıklı ortalama (weighted avg) değerleri raporda yer almaktadır.

Rapora göre, modelin doğruluk oranı %96 olarak hesaplanmıştır, yani modelin doğru sınıflandırma oranı oldukça yüksektir. Kesinlik ve duyarlılık değerleri incelendiğinde, her iki sınıf için de %95 ila %96 arasında yüksek değerlere sahip olduğu görülmektedir. Bu da modelin hem 0 sınıfını hem de 1 sınıfını başarıyla tahmin edebildiğini göstermektedir.

F1-skorları da her iki sınıf için yüksek olarak hesaplanmıştır (%95 ila %96). F1-skoru, kesinlik ve duyarlılık metriklerinin harmonik ortalamasını temsil eder ve bir sınıflandırma modelinin performansını tek bir değerle ölçer. Bu yüksek F1-skorları, modelin dengeli bir şekilde sınıflandırma yaptığını ve veri setindeki sınıfları başarıyla ayırt edebildiğini göstermektedir.

Makro-ortalama ve ağırlıklı ortalama değerleri de raporda yer almaktadır. Makro-ortalama, tüm sınıfların ortalamasını alarak elde edilen bir değerdir. Ağırlıklı ortalama ise sınıfların

etiketlenmiş örnek sayılarına göre ağırlıklı olarak hesaplanır. Her iki ortalama değeri de %96 olarak hesaplanmıştır.

Bu sınıflandırma raporu, modelin iyi bir performans sergilediğini ve veri setindeki sınıfları başarıyla sınıflandırdığını göstermektedir. Yüksek doğruluk, kesinlik, duyarlılık ve F1-skorları, modelin güvenilir sonuçlar ürettiğini göstermektedir.

Sınıflandırma Raporu:				
	precision	recall	f1-score	support
0	0.95	0.96	0.95	2712
1	0.96	0.95	0.96	2799
accuracy			0.96	5511
macro avg	0.96	0.96	0.96	5511
weighted avg	0.96	0.96	0.96	5511

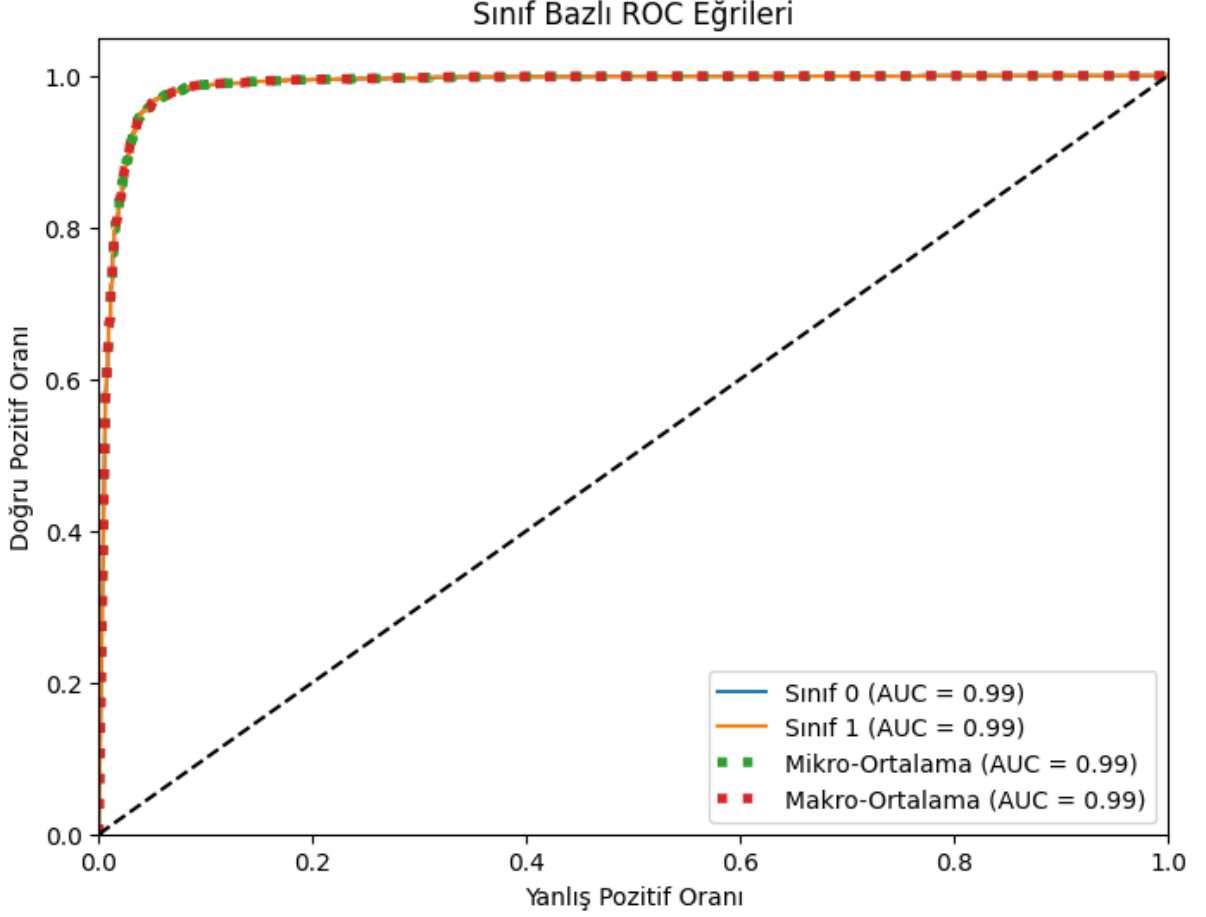
Şekil 31 Malaria Veri Seti Kullanılarak Oluşturulan CNN-LSTM Sınıflandırma Raporu

4.2.4. ROC EĞRİSİ VE AUC SKORU

ROC eğrisi ve AUC skoru hesaplamaları, her bir sınıf için ayrı ayrı yapılmıştır. Ayrıca, mikro-ortalama ve makro-ortalama ROC eğrileri ve AUC skorları da hesaplanmıştır. Mikro-ortalama ROC eğrisi ve AUC skoru, tüm sınıfların tahmin olasılıklarının birleştirilerek elde edilirken, makro-ortalama ROC eğrisi ve AUC skoru, her sınıfın ayrı ayrı hesaplanarak ortalaması alınarak elde edilir.

Bu modelde elde edilen Mikro-Ortalama AUC skoru 0.9867116996061595'dir. Makro-Ortalama AUC skoru 0.9869254427150025. Ayrıca, sınıf bazlı ROC eğrileri de grafiğe dökülmüştür. Her sınıf için ROC eğrisi çizilirken, eğrinin altında kalan alan AUC skoru olarak gösterilmiştir. Rastgele tahmin edilen ROC eğrisi de grafikte kırmızı kesikli çizgiyle gösterilmiştir.

Bu ROC eğrisi ve AUC skorları, modelin sınıfları doğru bir şekilde sınıflandırdığını ve yüksek bir sınıflandırma yeteneğine sahip olduğunu göstermektedir. Yüksek AUC skorları, modelin sınıf ayırımında başarılı olduğunu ve doğru pozitif oranını artırdığını göstermektedir.




Şekil 32 Malaria Veri Seti Kullanılarak Oluşturulan CNN-LSTM Sınıf Bazlı ROC Eğrileri

4.3. M-NSİT VERİ SETİ İÇİN CNN-KNN K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI

CNN-KNN hibrit modelinin performansını değerlendirmek için MNIST veri seti üzerinde deneyler gerçekleştirildi. Modeli eğitim veri seti üzerinde eğittik ve test veri seti üzerinde değerlendirdi. Ayrıca, 10 katlı çapraz doğrulama yöntemini kullanarak modelin genel performansını değerlendirdik.


4.3.1. DOĞRULUK DEĞERLERİ

Eğitim süreci boyunca, doğruluk ve kayıp değerlerini takip edildi. Aşağıda, eğitim ve test doğruluk değerlerinin epoch sayısına bağlı olarak nasıl değiştiğini gösteren grafikler yer alıyor.



Şekil 33 CNN-KNN M-NİST DOĞRULUK GRAFİĞİ

Kayıp grafiği incelendiğinde, eğitim süreci boyunca kaybın azaldığı ve modelin öğrenme yeteneğinin arttığı görülmektedir. Benzer şekilde, test veri setinde de kaybın azaldığı gözlenmektedir.



Şekil 34 CNN-KNN M-NİST KAYIP GRAFİĞİ

Eğitim ve test veri setleri üzerindeki doğruluk değerlerini hesapladık. Eğitim veri setindeki doğruluk değeri 0.9997166666666667, test veri setindeki doğruluk değeri ise 0.9917 olarak hesaplandı. Bu sonuçlar, modelin eğitim ve test veri setlerinde iyi bir performans sergilediğini göstermektedir.

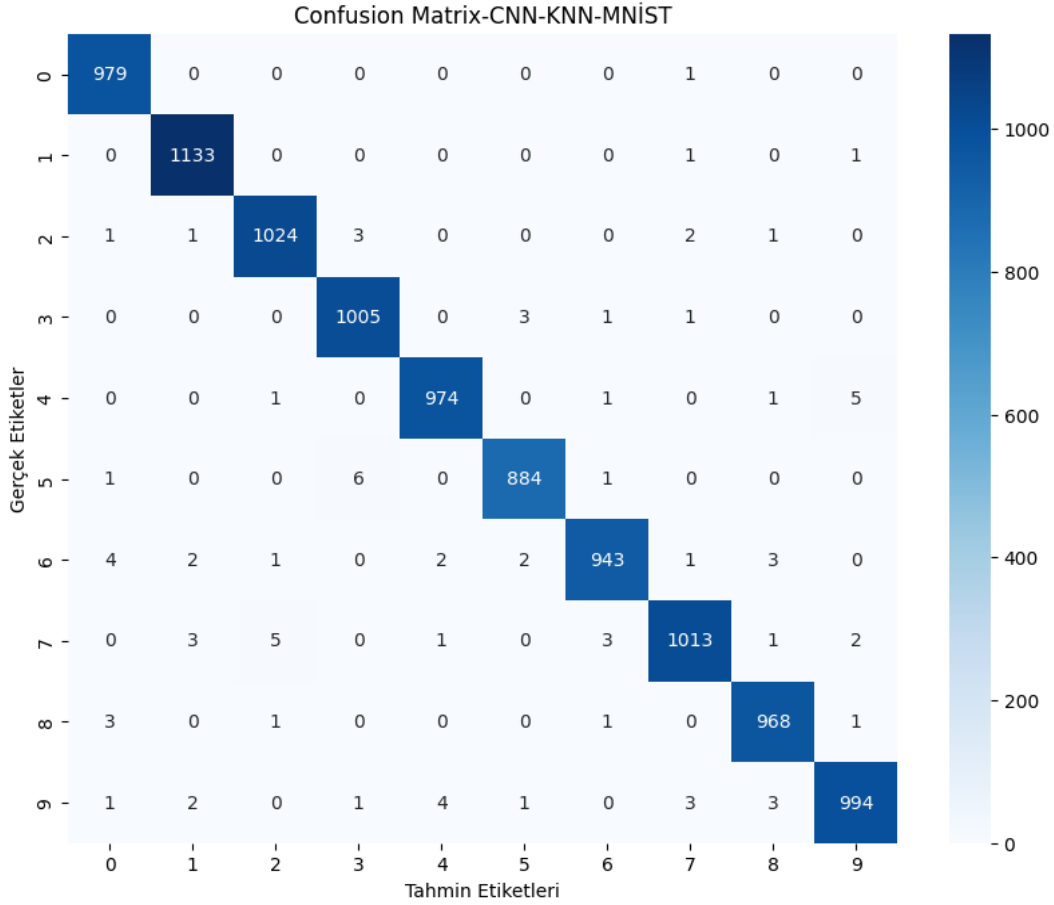
4.3.2. CONFUSION MATRIX

Modelin sınıflandırma performansını daha detaylı bir şekilde değerlendirmek için confusion matrix incelendi.

Confusion Matrix (karmaşıklık matrisi), bir sınıflandırma modelinin performansını değerlendirmek için kullanılan bir tablodur. Confusion matrix, modelin gerçek ve tahmin edilen sınıf etiketlerini karşılaştırarak dört farklı sonucu gösterir.

Bunlar True Positive (TP), True Negative (TN), False Positive (FP), False Negative (FN) değerleridir.

Bu matrisi kullanarak, modelin hangi sınıflarda daha iyi veya daha zayıf performans gösterdiğini analiz edildi.



Şekil 35 CNN-KNN M-NİST Veri Seti Kullanarak Oluşturulan Confusion Matrix

4.3.3. SINIFLANDIRMA RAPORU

Sınıflandırma raporu, her bir sınıf için precision, recall, f1-score ve destek değerlerini içermektedir. Bu metrikler, modelin sınıflandırma performansını daha ayrıntılı bir şekilde değerlendirmemize yardımcı olmuştur.

Sonuçlarınız incelendiğinde, her bir sınıf için yüksek precision, recall ve F1-score değerlerine sahip olduğunuz görülüyor. Bu, modelinizin yüksek performans gösterdiği anlamına gelir. Her sınıf için F1-score değerlerinin 0.99 olduğu gözlemleniyor, bu da modelinizin sınıfları doğru bir şekilde tahmin etme yeteneğinin yüksek olduğunu gösterir.

Bu sonuçlar, modelin MNIST veri kümesi üzerinde yüksek bir doğruluk elde ettiğini ve genel olarak iyi bir sınıflandırma performansına sahip olduğunu göstermektedir.

Sınıflandırma Raporu:				
	precision	recall	f1-score	support
0	0.99	1.00	0.99	980
1	0.99	1.00	1.00	1135
2	0.99	0.99	0.99	1032
3	0.99	1.00	0.99	1010
4	0.99	0.99	0.99	982
5	0.99	0.99	0.99	892
6	0.99	0.98	0.99	958
7	0.99	0.99	0.99	1028
8	0.99	0.99	0.99	974
9	0.99	0.99	0.99	1009
accuracy			0.99	10000
macro avg	0.99	0.99	0.99	10000
weighted avg	0.99	0.99	0.99	10000


Şekil 36 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-KNN Sınıflandırma Raporu

4.3.4. ROC EĞRİSİ AUC SKORU

Mikro-ortalama AUC skoru, tüm sınıfların birleşik olarak değerlendirildiği ve her bir örneğin doğru sınıflandırılma olasılığını temsil eden bir metriktir. Mikro-ortalama AUC skoru, tüm sınıfların örneklerini bir araya getirerek tek bir ROC eğrisi oluşturur ve bu eğri altında kalan alanı hesaplar. Bu durumda, mikro-ortalama AUC skoru 0.9959290277777778 olarak hesaplanmıştır. Bu değer, modelin çok yüksek bir ortalama sınıflandırma başarısına sahip olduğunu gösterir. Model, tüm sınıfların birleşik olarak doğru bir şekilde sınıflandırma yeteneğine sahiptir.

Makro-ortalama AUC skoru ise her bir sınıfın ayrı ayrı değerlendirildiği ve daha sonra bu sınıfların ortalamasının alındığı bir metriktir. Makro-ortalama AUC skoru, sınıf bazında performansın eşit olarak değerlendirildiği bir ölçüdür. Bu durumda, makro-ortalama AUC skoru 0.995892475819334 olarak hesaplanmıştır. Bu değer, modelin her bir sınıf için yüksek bir sınıflandırma performansına sahip olduğunu ve sınıf bazında dengeli bir şekilde doğru tahminler yaptığını gösterir.

Her iki AUC skoru da yüksek olduğundan, modelin MNIST veri kümesinde genel olarak iyi bir sınıflandırma performansı sergilediği ve ROC eğrisi altında kalan alanın yüksek olduğu söylenebilir. Bu sonuçlar, modelin sınıfları doğru bir şekilde ayırt etme yeteneğinin yüksek olduğunu ve sınıflar arasında iyi bir ayırım yapabildiğini göstermektedir.



Şekil 37 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-KNN Sınıf Bazlı ROC Eğrileri


4.4. MALARİA VERİ SETİ İÇİN CNN-KNN K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI

Bu çalışmada, Malaria veri seti üzerinde CNN-KNN hibrit bir sınıflandırma modeli değerlendirilmiştir. Veri seti, "Parasitized" ve "Uninfected" olmak üzere 2 farklı sınıfa ait görüntülerden oluşmaktadır. Model, veri setinin büyüklüğüne ve özelliklerine bağlı olarak eğitim ve test aşamalarında başarımını değerlendirmek için K-katlı çapraz doğrulama yöntemi kullanılarak bir sınıflandırma modeli değerlendirildi. Veri seti, 2 farklı sınıfa ait örneklerden oluşuyor. Model, eğitim veri seti üzerinde eğitildi ve ardından test veri seti üzerinde performansı değerlendirildi.

CNN-KNN hibrit modelinin performansını değerlendirmek için Malaria veri seti üzerinde deneyler gerçekleştirildi.

4.4.1. DOĞRULUK DEĞERLERİ


Eğitim süreci boyunca, doğruluk ve kayıp değerlerini takip edildi. Aşağıda, eğitim ve test doğruluk değerlerinin epoch sayısına bağlı olarak nasıl değiştiğini gösteren grafikler yer alıyor.



Şekil 38 CNN-KNN Malaria DOĞRULUK GRAFİĞİ

Görüldüğü üzere, model eğitim sürecinde yüksek bir doğruluk elde etmiştir. Ancak, test veri seti üzerindeki doğruluk değeri, eğitim veri seti üzerindeki doğruluktan biraz daha düşüktür, bu da modelin genelleme yeteneğine işaret etmektedir.

Kayıp grafiği incelendiğinde, eğitim süreci boyunca kaybın azaldığı ve modelin öğrenme yeteneğinin arttığı görülmektedir. Benzer şekilde, test veri setinde de kaybın arttığı görülüyor.

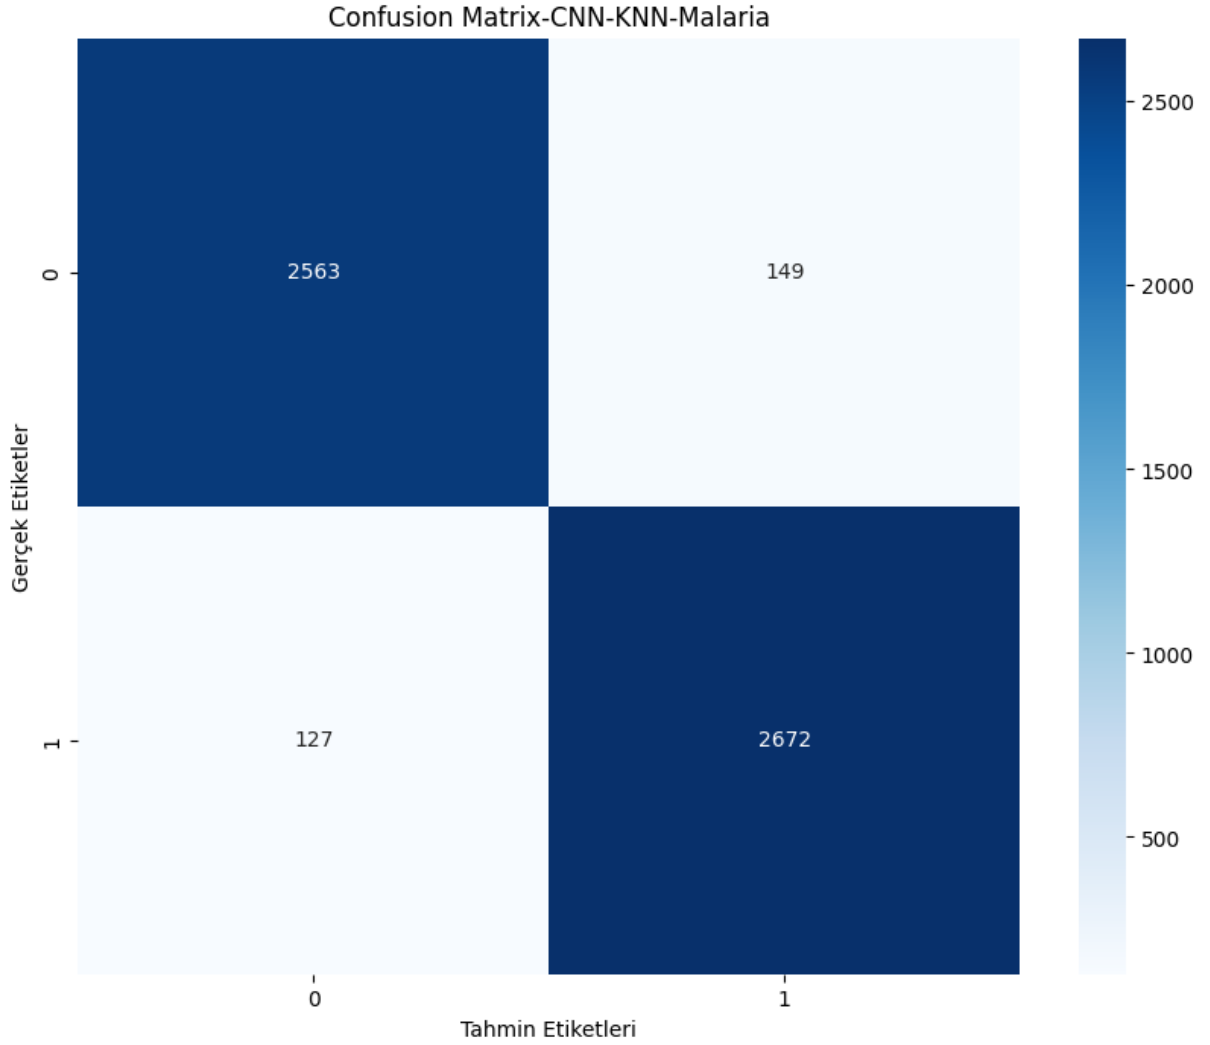


Şekil 39 CNN-KNN Malaria KAYIP GRAFİĞİ

Eğitim ve test veri setleri üzerindeki doğruluk değerlerini hesapladık. Eğitim veri setindeki doğruluk değeri 1.0, test veri setindeki doğruluk değeri ise 0.949918345127926 olarak hesaplandı. Bu sonuçlar, modelin eğitim ve test veri setlerinde iyi bir performans sergilediğini göstermektedir.

4.4.2. CONFUSION MATRIX

İdeal bir durumda, tüm örnekler doğru bir şekilde tahmin edildiğinde, matrisin köşegenindeki değerler (sol üstten sağ alta) yüksek olacaktır. Bu matriste, sol üst ve sağ alt köşegenlerdeki değerler yüksek olduğu için, modelin genel olarak iyi bir performans sergilediği söylenebilir. Ancak, sol üst köşegende bulunan yanlış tahmin edilen 149 örnek ve sağ alt köşegende bulunan 127 yanlış tahmin edilen örnek dikkate alınmalı ve iyileştirme yapılması gereken alanları gösterebilir.



Şekil 40 CNN-KNN Malaria Veri Seti Kullanarak Oluşturulan Confusion Matrix

4.4.3. SINIFLANDIRMA RAPORU

Sınıflandırma raporuna göre, modelin her iki sınıf için de yüksek hassasiyet (precision), duyarlılık (recall) ve F1-score değerleri elde ettiği görülmektedir. Her iki sınıf için de yaklaşık olarak %95'lik bir doğruluk oranı elde edilmiştir.

Sonuç olarak, bu modelin Malaria veri setinde yüksek bir performans sergilediği söylenebilir. Hem parazitized hem de uninfected sınıfları doğru bir şekilde sınıflandırma yeteneğine sahip olması, modelin hastalık teşhisinde kullanılabilir potansiyele sahip olduğunu göstermektedir.

Sınıflandırma Raporu:				
	precision	recall	f1-score	support
0	0.95	0.95	0.95	2712
1	0.95	0.95	0.95	2799
accuracy			0.95	5511
macro avg	0.95	0.95	0.95	5511
weighted avg	0.95	0.95	0.95	5511

Şekil 41 Malaria Veri Seti Kullanılarak Oluşturulan CNN-KNN Sınıflandırma Raporu


4.4.4. ROC EĞRİSİ AUC SKORU

Makro AUC skoru ve Mikro AUC skoru değerleri her iki sınıf için de 0.9498428247129981 olarak hesaplanmıştır.

Makro AUC skoru, her sınıfın AUC skorunu hesaplar ve ardından bu skorları sınıf sayısına göre ortalama alır. Bu durumda, her iki sınıf için de AUC skorları yaklaşık olarak aynı olduğu için makro AUC skoru da 0.9498428247129981 olarak hesaplanmıştır. Makro AUC skoru, her sınıfın aynı derecede önemli olduğu durumlarda kullanılır.

Mikro AUC skoru ise, tüm sınıfların tahminlerini birleştirerek tek bir ROC eğrisi ve AUC skoru hesaplar. Bu durumda, her iki sınıfın AUC skorları eşit olduğu için mikro AUC skoru da 0.9498428247129981 olarak hesaplanmıştır. Mikro AUC skoru, sınıflar arasındaki dengesizlik durumunda kullanılır.

Bu sonuçlar, modelin sınıflandırma yeteneklerinin yüksek olduğunu ve doğru pozitif oranı ile yanlış pozitif oranı arasında iyi bir denge sağladığını göstermektedir. Modelin hastalığın varlığını doğru bir şekilde tahmin etme yeteneğini ve iyi bir ayırım yapma performansını göstermektedir.




Şekil 42 Malaria Veri Seti Kullanılarak Oluşturulan CNN-KNN Sınıf Bazlı ROC Eğrileri

4.5. M-NİST VERİ SETİ İÇİN CNN-SVMN K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI


CNN-KNN hibrit modelinin performansını değerlendirmek için MNIST veri seti üzerinde deneyler gerçekleştirdi. Modeli eğitim veri seti üzerinde eğittik ve test veri seti üzerinde değerlendirdi. Ayrıca, 10 katlı çapraz doğrulama yöntemini kullanarak modelin genel performansını değerlendirdik.

4.5.1. DOĞRULUK DEĞERLERİ

Eğitim süreci boyunca, doğruluk ve kayıp değerlerini takip edildi. Aşağıda, eğitim ve test doğruluk değerlerinin epoch sayısına bağlı olarak nasıl değiştiğini gösteren grafikler yer alıyor.



Şekil 43 CNN-SVM M-NİST DOĞRULUK GRAFİĞİ




Şekil 44 CNN-SVM M-NİST KAYIP GRAFİĞİ

Eğitim ve test veri setleri üzerindeki doğruluk değerlerini hesapladık. Eğitim veri setindeki doğruluk değeri 0.99995, test veri setindeki doğruluk değeri ise 0.9918 olarak hesaplandı. Bu sonuçlar, modelin eğitim ve test veri setlerinde iyi bir performans sergilediğini göstermektedir.

4.5.2. CONFUSION MATRIX

MNIST veri seti üzerinde gerçekleştirilen CNN-SVM hibrit modelinin performansını değerlendirmek için bir karmaşıklık matrisi eklendi. Karmaşıklık matrisi, el yazısı rakamlarını doğru ve yanlış tahmin eden modelin performansını gösteren bir metriktir. Matris, modelin true positive (doğru pozitif), false positive (yanlış pozitif), true negative (doğru negatif) ve false negative (yanlış negatif) değerlerini içerir. Bu matris, modelimin doğruluk, hassasiyet, özgüllük ve hata oranı gibi performans ölçütlerini görselleştirmeye yardımcı olmaktadır.



Şekil 45 CNN-SVM M-NIST Veri Seti Kullanarak Oluşturulan Confusion Matrix

4.5.3. SINIFLANDIRMA RAPORU

Modelin doğruluk, kesinlik, hatırlama ve F1-skor değerleri oldukça yüksek seviyelerdedir. Bu durum, modelin sınıflandırma görevini başarılı bir şekilde gerçekleştirdiğini ve tahminlerin güvenilir olduğunu göstermektedir.

Precision (kesinlik) değerleri, her sınıf için doğru tahminlenen örneklerin oranını temsil eder. Tüm sınıflar için yüksek kesinlik değerleri elde edilmiştir. Bu da modelin sınıfları doğru bir şekilde tahmin etme konusunda başarılı olduğunu göstermektedir.

Recall (hatırlama) değerleri, gerçek pozitiflerin doğru bir şekilde tahmin edilme oranını ifade eder. Tüm sınıflar için yüksek hatırlama değerleri elde edilmiştir. Bu da modelin gerçek sınıfları doğru bir şekilde tespit etme yeteneğine sahip olduğunu göstermektedir.

F1-skor değerleri, kesinlik ve hatırlama metriklerinin harmonik ortalamasını temsil eder. Tüm sınıflar için yüksek F1-skor değerleri elde edilmiştir. Bu da modelin sınıflandırma performansının dengeli olduğunu göstermektedir.

Ayrıca, genel doğruluk değeri de oldukça yüksek bir seviyededir. Model, tüm örnekleri doğru bir şekilde sınıflandırmıştır.

Bu sınıflandırma raporu sonuçları, modelin yüksek performans sergilediğini ve sınıfları doğru bir şekilde tahmin ettiğini göstermektedir.


Sınıflandırma Raporu:				
	precision	recall	f1-score	support
0	0.99	1.00	0.99	980
1	1.00	1.00	1.00	1135
2	0.99	0.99	0.99	1032
3	0.99	1.00	0.99	1010
4	0.99	0.99	0.99	982
5	0.99	0.98	0.99	892
6	1.00	0.99	0.99	958
7	0.99	0.99	0.99	1028
8	0.99	0.99	0.99	974
9	0.99	0.98	0.99	1009
accuracy			0.99	10000
macro avg	0.99	0.99	0.99	10000
weighted avg	0.99	0.99	0.99	10000

Şekil 46 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-SVM Sınıflandırma Raporu

4.5.4. ROC EĞRİSİ VE AUC SKORU

Bu modelde elde edilen Mikro-Ortalama AUC skoru 0.99972041'dir. Makro-Ortalama AUC skoru 0.9997301651540647'dir. Ayrıca, rastgele tahmin edilen ROC eğrisi de gösterilmiştir. Bu eğri, modelin tamamen rastgele tahminlerde bulunduğu bir senaryoyu temsil eder. Modelin ROC eğrisinin rastgele tahmin edilen eğriye göre daha yüksek bir yerde olması, modelin sınıflandırma yeteneğinin rastgele tahminden daha iyi olduğunu gösterir.

Grafik, doğru pozitif oranının yanlış pozitif oranına göre yüksek değerlere ulaştığını ve modelin iyi bir sınıflandırma performansına sahip olduğunu göstermektedir. Ayrıca, sınıf bazlı AUC skorları da gösterilmiştir. Bu skorlar, her bir sınıfın tahmin performansını ölçer ve modelin her sınıfı ne kadar iyi sınıflandırdığını gösterir.




Şekil 47 M-NİST Veri Seti Kullanılarak Oluşturulan CNN-SVM Sınıf Bazlı ROC Eğrileri

4.6. MALARİA VERİ SETİ İÇİN CNN-SVMN K-KATLI ÇAPRAZ DOĞRULAMA SONUÇLARI


Bu çalışmada, Malaria veri seti üzerinde CNN-SVM hibrit bir sınıflandırma modeli değerlendirilmiştir. Veri seti, "Parasitized" ve "Uninfected" olmak üzere 2 farklı sınıfa ait görüntülerden oluşmaktadır. Model, veri setinin büyüklüğüne ve özelliklerine bağlı olarak eğitim ve test aşamalarında başarımını değerlendirmek için K-katlı çapraz doğrulama yöntemini kullanmıştır. Bu çalışmada, Malaria veri seti üzerinde CNN-KNN hibrit bir sınıflandırma modeli değerlendirilmiştir. Veri seti, "Parasitized" ve "Uninfected" olmak üzere 2 farklı sınıfa ait görüntülerden oluşmaktadır. Model, veri setinin büyüklüğüne ve özelliklerine bağlı olarak eğitim ve test aşamalarında başarımını değerlendirmek için K-katlı çapraz doğrulama yöntemini kullanmıştır.

4.6.1. DOĞRULUK DEĞERLERİ

Eğitim sürecinde, modelin doğruluk ve kayıp değerleri takip edilmiştir. Aşağıdaki grafikler, eğitim ve doğrulama doğruluk değerlerinin epoch sayısı arttıkça nasıl değiştiğini göstermektedir.



Şekil 48 CNN-SVM Malaria DOĞRULUK GRAFİĞİ



Şekil 49 CNN-SVM Malaria KAYIP GRAFİĞİ

Grafiklere bakıldığında, modelin eğitim sürecinde yüksek bir doğruluk elde ettiği görülmektedir. Ancak, test veri seti üzerindeki doğruluk değeri, eğitim veri setindeki doğruluktan biraz daha düşük olabilir. Kayıp grafiği incelendiğinde, eğitim süreci boyunca kaybın azaldığı ve modelin öğrenme yeteneğinin arttığı görülmektedir. Benzer şekilde, test veri setinde kaybın arttığı görülmektedir.

Eğitim ve test veri setleri üzerindeki doğruluk değerleri aşağıdaki şekildedir:


Eğitim verisi doğruluğu: 0.9997407983411094

Test verisi doğruluğu: 0.9401197604790419

Bu sonuçlar, modelin eğitim ve test veri setlerinde iyi bir performans sergilediğini göstermektedir.

4.6.2. CONFUSION MATRIX

Bu çalışmada, Malaria veri kümesi üzerinde bir sınıflandırma modeli kullanarak hastaların enfekte veya sağlıklı olduğunu tahmin etmeyi amaçlandı. Kullanılan hibrit modelin performansını değerlendirmek için karmaşıklık matrisini kullanarak gerçek etiketlerin ve tahmin edilen etiketlerin sayısal değerleri incelendi. Elde edilen karmaşıklık matrisi aşağıdaki gibidir.



Şekil 50 CNN-SVM Malaria Veri Seti Kullanarak Oluşturulan Confusion Matrix

Bu sonuçlar, modelimizin Malaria teşhisinde iyi bir performans gösterdiğini göstermektedir.

4.6.3. SINIFLANDIRMA RAPORU

Malaria veri kümesi üzerinde gerçekleştirilen sınıflandırma modelinin performansını değerlendirmek için sınıf 0 (Malaria enfeksiyonu olmayan) ve sınıf 1 (Malaria enfeksiyonu olan) için precision (kesinlik), recall (geri çağırma) ve f1-score (F1 puanı) gibi metrikler kullanılarak bir sınıflandırma raporu sunulmuştur. Bu rapor, modelin sınıf 0 ve sınıf 1 örneklerini doğru bir şekilde tahmin etme yeteneğini ve genel performansı değerlendirilmiştir. Sonuçlar aşağıda verilmiştir;

Sınıflandırma Raporu:					
	precision	recall	f1-score	support	
0	0.96	0.92	0.94	2712	
1	0.92	0.96	0.94	2799	
accuracy			0.94	5511	
macro avg	0.94	0.94	0.94	5511	
weighted avg	0.94	0.94	0.94	5511	


Şekil 51 Malaria Veri Seti Kullanılarak Oluşturulan CNN-SVM Sınıflandırma Raporu

4.6.4. ROC EĞRİSİ VE AUC SKORU

Bu çalışmada elde edilen sonuçlara göre, mikro-ortalama AUC skoru 0.9397552697391924 ve makro-ortalama AUC skoru 0.9397552697391924 olarak hesaplanmıştır. Mikro-ortalama AUC skoru, modelin tüm sınıflar üzerindeki performansını temsil ederken, makro-ortalama AUC skoru sınıf bazında performansın ortalamasını vermektedir.

Sınıf bazlı ROC eğrileri, her bir sınıfın ayrı ayrı ROC eğrisini ve ilgili AUC skorunu göstermektedir. Ayrıca, mikro-ortalama ROC eğrisi ve makro-ortalama ROC eğrisi de grafik üzerinde gösterilmiştir. Rastgele tahmin edilen ROC eğrisi ise bir referans olarak çizilmiştir.

Bu analizler, sınıflandırma modelinin sınıf bazlı performansını ve genel etkinliğini daha ayrıntılı bir şekilde değerlendirmemizi sağlamaktadır. ROC eğrileri ve AUC skoru, modelin sınıflar arasındaki ayırım yeteneğini, hassasiyetini ve özgüllüğünü gösteren önemli ölçütlerdir.



Şekil 52 Malaria Veri Seti Kullanılarak Oluşturulan CNN-SVM Sınıf Bazlı ROC Eğrileri

5. KAYNAKÇA

- [1] M. K. G. Y. Z. Ö. Erkan TANYILIDIZI, «Siğil Tedavisinde Sınıflandırma Algoritmalarının Performans Analizi,» *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, cilt 30, no. 2, pp. 249-256, 2018.
- [2] İ. T. Ferdi DOĞAN, «Derin Öğrenme Modelleri ve Uygulama Alanlarına İlişkin Bir Derleme,» *Dicle Üniversitesi Mühendislik Fakültesi Mühendislik Dergisi*, cilt 10, no. 2, pp. 409-445, 2019.
- [3] A. D. Ulaş Alperen COŞKUN, «Farklı Çiçek Türlerini Derin Öğrenme Yöntemi İle Tanıma,» *Dokuz Eylül Üniversitesi Mühendislik Fakültesi Fen ve Mühendislik Dergisi*, cilt 24, no. 70, pp. 55-64, 2022.
- [4] S. A. T. F. B. Aslı SESLİ, «Plantar Basınç Dağılımı Sinyalleri Kullanılarak Erken MS'ilerde Ataksinin Hybrt CNN Modelleri ile Belirlenmesi,» *Avrupa Bilim ve Teknoloji Dergisi*, no. 28, pp. 579-583, 2021.
- [5] T. A. Ebru ERDEM, «A CNN-based hybrid model to detect Coronavirus disease,» *Avrupa Bilim ve Teknoloji Dergisi*, no. 27, pp. 66-73, 2021.
- [6] N. B. H. M. Ü. Berker BAYDAN, «Hibrit Mask R-CNN Mimarisi Kullanılarak Köpek ve Kedi Tibia Kırık Yerinin Belirlenmesi,» *Kafkas Üniversitesi Veteriner Fakültesi Dergisi*, pp. 347-353, 2021.
- [7] J. L. L. W. M. W. Y. G. Pengpeng Ding, «HYBRID-CNN: An Efficient Scheme for Abnormal Flow Detection in the SDN-Based Smart Grid,» *Hindawi Security and Communication Networks*, p. 20, 2020.
- [8] Q. Y. S. D. Lisha Xiao, «Scene classification with improved AlexNet model,» %1 içinde *2017 12th International Conference on Intelligent Systems and Knowledge Engineering (ISKE)*, China, 2017.
- [9] K. K. H. M. E. Ahmet EKİZ, «CNN ve Con-SVM Kullanarak Beyaz Kan Hücrelerinin Sınıflandırılması,» %1 içinde *Sinyal İşleme ve İletişim Uygulamaları Konferansı (SIU)*, İstanbul, 2021.

- [10] E. Ö. Ahmet CİRAN, «Ön-Eğitilmiş CNN Mimarilerinin Füzyonu ile Mısır Yaprağı Hastalıklarının Sınıflandırılması,» *Avrupa Bilim ve Teknoloji Dergisi*, no. 44, pp. 74-83, 2022.
- [11] M. M. R. T. M. S. S. N. I. K. S. K. D. Mohammad Shahjahan Majib, «VGG-SCNet: A VGG Net-Based Deep Learning Framework for Brain Tumor Detection on MRI Images,» cilt 9, pp. 116942-116952, 2021.
- [12] B. ELMAS, «Evrimsel sinir ağı ile mermer ve granit çeşitlerinin transfer öğrenme yöntemiyle sınıflandırılması,» *Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi*, cilt 37, no. 2, pp. 985 - 1002, 2022.
- [13] H. Çetiner, «Cnn ve lstm tabanlı hibrit bir derin öğrenme modeli ile çok etiketli metin analizi,» *Adıyaman Üniversitesi Mühendislik Bilimleri Dergisi*, cilt 9, no. 17, pp. 447-457, 2022.
- [14] T. İ. Ayşe Zeynel Pekoz, «Demand forecasting with deep learning: Case study in a third-party logistics company for the COVID-19 period,» *Pamukkale Üniversitesi Mühendislik Bilimleri Dergisi*, cilt 28, no. 7, 2022.
- [15] M. TOĞAÇAR, «Harflerden Oluşan Genişletilmiş MNIST Veri Kümesinin Derin Öğrenme Tabanlı Tasarlanmış Sinir Ağı Modeli ile Sınıflandırılması,» *Çukurova Üniversitesi Mühendislik Fakültesi Dergisi*, cilt 36, no. 3, pp. 681 - 690, 2021.
- [16] İ. ÇETİNER, «KONVOLÜSYONEL SİNİR AĞI KULLANILARAK SİTMA HASTALIĞI SINIFLANDIRILMASI,» *Adıyaman Üniversitesi Mühendislik Bilimleri Dergisi*, cilt 9, no. 17, pp. 273-286, Aug. 2022.
- [17] M. K. Abdullah ALAN, «Veri Seti - Sınıflandırma İlişkisinde Performansa Etki Eden Faktörlerin Değerlendirilmesi,» *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, cilt 32, no. 2, pp. 531-540, Sep. 2020.
- [18] E. KARTAL, MAKİNE ÖĞRENMESİ VE YAPAY ZEKÂ, İstanbul: Dr., İstanbul Üniversitesi, Enformatik Bölümü, 2021.

- [19] H. E. B. H. G. A. Ç. S. Zafer Kaya, «MACHINE LEARNING APPROACH TO DETERMINING FRACTURE,» %1 içinde 5. *International Conference on Material Science and Technology (IMSTEC 2020)*, 2020.
- [20] C. Wong, «Sinir Ağı Sınıflandırıcıları Arasında Veri Madenciliği Yanlılığine Karşı Güvenlik Açığı Konusunda Yeni Bir Operasyonel Bölme,» *Journal of Software Engineering and Applications*, cilt 7, no. 4, pp. 273-297, 14 Nisan 2014.
- [21] C. J. Burges, «A Tutorial on Support Vector Machines for Pattern Recognition,» *Data Mining and Knowledge Discovery*, cilt 2, no. 2, p. 121–167, 1998.
- [22] C. M. Bishop, Örüntü Tanıma ve Makine Öğrenimi, 1 dü., Cilt %1 / %2978-0-387-31073-2, Springer New York, NY, 2006, p. 738.
- [23] J. F. ., R. T. Trevor Hastie, İstatistiksel Öğrenmenin Unsurları, 1 dü., Springer New York, NY, 2009, pp. XVI, 536.
- [24] H. W. D. B. Y. B. & K. G. Gongde Guo, KNN Model-Based Approach in Classification, cilt 2888, Springer, Berlin, Heidelberg, 2003.
- [25] D. B. Gizem DİLKİ Özlem, «İŞLETMELERİN İFLAS TAHMİNİNDE K- EN YAKIN KOMŞU ALGORİTMASI ÜZERİNDEN UZAKLIK ÖLÇÜTLERİNİN KARŞILAŞTIRILMASI,» *İstanbul Ticaret Üniversitesi Fen Bilimleri Dergisi*, cilt 19, no. 38, pp. 224-233, Aralık 2020.
- [26] A. D. M. F. E. O. V. Ülkü VERANYURT, «MAKİNE ÖĞRENMESİ TEKNİKLERİYLE HASTALIK SINIFLANDIRMASI: RANDOM FOREST, K-NEAREST NEIGHBOUR VE ADABOOST ALGORİTMALARI UYGULAMASI,» *Uluslararası Sağlık Yönetimi ve Stratejileri Araştırma Dergisi*, cilt 6, no. 2, pp. 275-286, Ağustos 2020.
- [27] İ. T. Ferdi DOĞAN, «Derin Öğrenme Modelleri ve Uygulama Alanlarına İlişkin Bir Derleme,» *Dicle Üniversitesi Mühendislik Fakültesi Mühendislik Dergisi*, cilt 10, no. 2, pp. 409-445, 2019.
- [28] S. S. B. M. Ş. Muhammed Abdullah ÖZEL, «Derin Öğrenme Algoritması (YOLO) ile Dinamik Test Süresince Süspansiyon Parçalarında Çatlak Tespiti,» *Avrupa Bilim ve Teknoloji Dergisi*, no. 26, pp. 1-5, 2021.

- [29] İ. H. C. Gül GÜNDÜZ, «Gender Estimation with Image by Using Deep Learning Algorithms,» *SAKARYA UNIVERSITY JOURNAL OF COMPUTER AND INFORMATION SCIENCES*, cilt 2, no. 1, pp. 9-17, 2019.
- [30] A. Yılmaz, «Diagnosing COVID-19 from X-Ray images with using multi-channel CNN architecture,» *Journal of the Faculty of Engineering and Architecture of Gazi University*, pp. 1761-1774, 2021.
- [31] T. Ergin, «Medium,» 2 Jan 2018. [Çevrimiçi]. Available: <https://medium.com/@tuncerergin/convolutional-neural-network-convnet-yada-cnn-nedir-nasil-calisir-97a0f5d34cad>. [Erişildi: 20 Dec 2022].
- [32] E. Ü. Özkan İNİK, «Derin Öğrenme ve Görüntü Analizinde Kullanılan Derin Öğrenme Modelleri,» *Gaziosmanpaşa Bilimsel Araştırma Dergisi*, cilt 6, no. 3, pp. 85-104, 2017.
- [33] İ. H. C. Gül GÜNDÜZ, «Gender Estimation with Image by Using Deep Learning Algorithms,» *SAKARYA UNIVERSITY JOURNAL OF COMPUTER AND INFORMATION SCIENCES*, cilt 2, no. 1, pp. 9-17, 2019.
- [34] İ. H. C. Gül GÜNDÜZ, «Gender Estimation with Image by Using Deep Learning Algorithms,» *SAKARYA UNIVERSITY JOURNAL OF COMPUTER AND INFORMATION SCIENCES*, cilt 2, no. 1, pp. 9-17, 2019.
- [35] E. Ü. Özkan İNİK, «Derin Öğrenme ve Görüntü Analizinde Kullanılan Derin Öğrenme Modelleri,» *Gaziosmanpaşa Bilimsel Araştırma Dergisi*, cilt 6, no. 3, pp. 85-104, 2017.
- [36] E. Ü. Özkan İNİK, «Derin Öğrenme ve Görüntü Analizinde Kullanılan Derin Öğrenme,» *Gaziosmanpaşa Bilimsel Araştırma Dergisi*, cilt 6, no. 3, pp. 85-104, 2017.
- [37] İ. H. C. Gül GÜNDÜZ, «Gender Estimation with Image by Using Deep Learning Algorithms,» *SAKARYA UNIVERSITY JOURNAL OF COMPUTER AND INFORMATION SCIENCES*, cilt 2, no. 1, 2019.
- [38] İ. T. Ferdi DOĞAN, «Derin Öğrenme Modelleri ve Uygulama Alanlarına İlişkin Bir Derleme,» *Dicle Üniversitesi Mühendislik Fakültesi Mühendislik Dergisi*, cilt 10, no. 2, pp. 409-445, 2019.

- [39] B. E. F. Ö. Mesut TOĞAÇAR, «Evrişimsel Sinir Ağı Modellerinde Özellik Seçim Yöntemlerini Kullanarak Çiçek Görüntülerinin Sınıflandırılması,» *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, cilt 32, no. 1, pp. 47-56, 2020.
- [40] S. Çilek, «Medium,» 9 Aug 2021. [Çevrimiçi]. Available: <https://suhedacilek.medium.com/resnet-residual-network-nedir-49105e642566>. [Erişildi: 1 Jan 2023].
- [41] J. S. Sepp Hochreiter, «Long Short-Term Memory,» *Neural Computation*, cilt 9, no. 8, pp. 1735 - 1780, 15 Kasım 1997.
- [42] A. Graves, «Generating Sequences With Recurrent Neural Networks,» *Neural and Evolutionary Computing*, 5 Haziran 2014.
- [43] R. K. S. J. K. B. R. S. J. S. Klaus Greff, «LSTM: A Search Space Odyssey,» *Neural and Evolutionary Computing*, cilt 28, no. 10, pp. 2222 - 2232, 13 Mart 2015.
- [44] A. M. & A. Mohammed, A Survey on Deep Learning for Time-Series Forecasting, cilt 77, Springer, Cham, 2020, pp. 365-392.